

**UNIVERSIDAD MAYOR DE SAN ANDRÉS
FACULTAD DE CIENCIAS PURAS Y NATURALES
CARRERA DE INFORMÁTICA**



TESIS

**RECONOCIMIENTO DE COPÉPODOS MEDIANTE REDES NEURONALES
ARTIFICIALES**

Postulante:	Verónica Milenka Encinas Picolomini
Tutor:	Lic. Mario Loayza Molina
Revisor:	PhD. Guillermo Choque Aspiazu
Asesor:	Lic. Ramiro Loza Herrera

**La Paz – Bolivia
2008**

DEDICACIÓN

*A mis padres,
por haberme brindado todo su amor
A mis hermanos
quienes son la fuente de energía de mi vida*

AGRADECIMIENTOS

Agradezco a Dios por haberme dado fortaleza para salir adelante, haberme cuidado cuando estaba sola y sobre todo por darme una gran familia, darme unos padres ejemplares que me enseñaron a luchar y unos hermanos que además de ser mi apoyo son mis mejores amigos, gracias a Dios por este pilar fundamental que ha sido y será mi inspiración personal.

También agradezco a mi tutor el Lic. Loayza que ha sido un guía en el desarrollo de la presente investigación.

Un especial agradecimiento a mi revisor PhD. Guillermo Choque por ser además de un ejemplo para mí, como profesional es también un modelo como persona, gracias por haber aceptado construir este trabajo conmigo.

Por ultimo quiero agradecer a mi asesor Lic. Ramiro Loza Herrera y a toda su familia por que me han colaborado innumerables veces y siempre les quedare agradecida, por haber soportado todas las molestias.

Verónica Milenka Encinas Picolomini

RESUMEN

El mundo esta creado de una forma realmente asombrosa todo se encuentra en perfecto equilibrio, parte de esta armonía, en el reino animal se encuentra en la cadena trófica alimenticia, esta cadena se identifica con el refrán que dice: “que el más grande se come al más pequeño”, al diminuto, microscópico en realidad, que muchas veces pasa desapercibido sin merecer la importancia que realmente tiene, este es el caso del copépodo un pequeño, microscópico crustáceo acuático, que protagoniza la presente investigación. El estudio de este microcrustáceo no es sencillo, debido principalmente a su tamaño, por eso mediante la investigación se presenta una solución para su reconocimiento, obteniendo un prototipo basado en redes neuronales artificiales que reconoce las especies de copépodos existentes en los Lagos Titicaca y Poopó, el reconocimiento se realiza por medio de imágenes fotográficas tomadas a través de un microscopio electrónico. El ambiente de trabajo es la Unidad de Limnología de la Carrera de Biología, Facultad de Ciencias Puras y Naturales, de la Universidad Mayor de San Andrés. Para el desarrollo del prototipo se aplican las bases de la ingeniería del software, con la metodología ágil Iconix y para comprobar la calidad del producto software se utilizan métricas de calidad orientadas a objetos, las cuales muestran resultados satisfactorios en su aplicación.

Palabras Clave: cadena trófica, copépodo, red neuronal artificial, patrón, filtros de imágenes.

ABSTRACT

The World was created in an amazing way, everything it is on perfect balance, part of this harmony, about the animal kingdom it is found it on nutritional chain, this chain is identify with that adage that said “the biggest eats to smallest”, too the little one, actually microscopic, that very times passes unseen without the importance than really has it. This is the case of the copepod a small or microscopic aquatic crustacean who is the protagonist of the investigation. The research of this small crustacean it is not simple, principally due to its size, and that is why by means of the investigation presents a solution for its recognition, obtaining a prototype based in artificial neuronal network that recognize the different species of copepods existents in the lakes Titicaca and Poopó, this recognize it is possible for photographical imagines takes trough the electronic microscope. The work environment is the Limnology Unity of the Biology College, School of Pures and Natural Sciences, of the Mayor de San Andres University. To the prototype’s development applies the bases of the software engineering, with the Agile Methodology Iconix and to the proved the quality uses quality metrics oriented to objects, these metrics shows satisfactory results in its application.

Key words: nutritional chain, copepod, artificial neuronal network, pattern, images filter.

ÍNDICE GENERAL

1. MARCO REFERENCIAL	1
1.1. INTRODUCCIÓN	1
1.2. ANTECEDENTES	1
1.3. PROBLEMA DE INVESTIGACIÓN	3
1.4. OBJETIVOS	4
1.5. ALCANCES	5
1.6. LÍMITES	5
1.7. HIPÓTESIS	5
1.8. JUSTIFICACIÓN DEL TEMA	5
1.9. ASPECTOS METODOLÓGICOS	7
2. COPÉPODOS	8
2.1. INTRODUCCIÓN	8
2.2. MORFOLOGÍA	8
2.3. REPRODUCCIÓN Y DESARROLLO	12
2.4. MOVILIDAD Y NUTRICIÓN	13
2.5. COMPOSICIÓN QUÍMICA Y EXCRECIÓN	15
2.6. UTILIDAD E IMPORTANCIA	15
2.7. DISTRIBUCIÓN	16
3. REDES NEURONALES ARTIFICIALES	18
3.1. INTRODUCCIÓN	18
3.2. REPRESENTACIÓN NEURONAL	18
3.3. PRINCIPIOS DE LA INGENIERÍA NEURONAL	28
3.4. METODOLOGÍA	32
3.5. RED DE RETROPROPAGACIÓN	34
4. MARCO APLICATIVO	42
4.1. MODELO DE RED NEURONAL	42
4.2. ANÁLISIS Y DISEÑO DEL PROTOTIPO	45
5. PRUEBAS Y MÉTRICAS DE CALIDAD	61
5.1. PRUEBAS PARA EL RECONOCIMIENTO DE LAS ESPECIES DE COPÉPODOS	61
5.2. MÉTRICAS DE CALIDAD ORIENTADAS A OBJETOS DEL PROTOTIPO	62
6. CONCLUSIONES Y RECOMENDACIONES	65
6.1. ESTADO DE LOS OBJETIVOS	65
6.2. ESTADO DE LA HIPÓTESIS	66
6.3. CONCLUSIONES	66
6.4. RECOMENDACIONES	66
6.6 TRABAJOS FUTUROS	66
7. BIBLIOGRAFÍA	68
ANEXO A: Glosario	70

ANEXO C: Árbol de Objetivos..... 75

ANEXOS B: Árbol de Problemas 74



ÍNDICE ESPECÍFICO

1. MARCO REFERENCIAL	1
1.1. INTRODUCCIÓN	1
1.2. ANTECEDENTES	1
1.3. PROBLEMA DE INVESTIGACIÓN	3
1.3.1. Planteamiento del problema	3
1.3.2. Formulación del problema	4
1.3.3. Problemas específicos	4
1.4. OBJETIVOS	4
1.4.1. Objetivo general	4
1.4.2. Objetivos específicos	4
1.5. ALCANCES	5
1.6. LÍMITES	5
1.7. HIPÓTESIS	5
1.8. JUSTIFICACIÓN DEL TEMA	5
1.8.1. Justificación metodológica	5
1.8.2. Justificación práctica	5
1.8.3. Justificación económica	6
1.8.4. Justificación social	6
1.8.5. Justificación técnica	6
1.9. ASPECTOS METODOLÓGICOS	7
1.9.1. Tipo de estudio	7
1.9.2. Método de investigación	7
2. COPÉPODOS	8
2.1. INTRODUCCIÓN	8
2.2. MORFOLOGÍA	8
2.2.1. Morfología externa	8
2.2.2. Morfología interna	12
2.3. REPRODUCCIÓN Y DESARROLLO	12
2.4. MOVILIDAD Y NUTRICIÓN	13
2.5. COMPOSICIÓN QUÍMICA Y EXCRECIÓN	15
2.6. UTILIDAD E IMPORTANCIA	15
2.6.1. Situación en las redes tróficas	15
2.6.2. Indicadores biológicos	15
2.7. DISTRIBUCIÓN	16
3. REDES NEURONALES ARTIFICIALES	18
3.1. INTRODUCCIÓN	18
3.2. REPRESENTACIÓN NEURONAL	18
3.2.1. Neurona Simple	20
3.2.2. Red neuronal	22
3.2.3. Neuronas artificiales	23
3.2.4. Transformación neuronal	24
3.3. PRINCIPIOS DE LA INGENIERÍA NEURONAL	27
3.3.1. Principio uno	27
3.3.2. Principio dos	28
3.3.3. Principio tres	28

3.4. METODOLOGÍA	29
3.4.1. Descripción del sistema	29
3.4.2. Especificación del diseño	30
3.4.3. Implementación	30
3.5. RED DE PROPAGACIÓN HACIA ATRÁS	31
3.5.1. Funcionamiento	33
3.5.2. Algoritmo	34
3.5.3. Datos de entrenamiento	35
3.5.4. Dimensionamiento de la red	36
3.5.5. Pesos y parámetros de aprendizaje	37
4. MARCO APLICATIVO	38
4.1. MODELO DE RED NEURONAL	38
4.1.1 Descripción del sistema	38
4.1.2. Especificación del diseño	40
4.2. ANÁLISIS Y DISEÑO DEL PROTOTIPO	41
4.2.1 Requerimientos	41
4.2.2 Actores	41
4.2.3. Diseño de Interfaces	41
4.2.3.1. Autentificador	41
4.2.3.2. Interfaz principal	42
4.2.3.3. Reconocimiento de imagen	42
4.2.3.4. Ver registros	43
4.2.4. Casos de uso	44
4.2.5. Casos de uso expandidos	45
4.2.6. Diagrama de secuencias	49
4.2.6.1. Insertar clave	49
4.2.6.2. Registrar usuario	50
4.2.6.3. Insertar imagen	50
4.2.6.4. Reconocer especie	51
4.2.6.5. Almacenar resultado	51
4.2.7. Diagrama de robustez	52
4.2.7.1. Insertar clave	52
4.2.7.2. Reconocer especie	53
4.2.7.3. Almacenar resultado	54
4.2.7.4. Registra usuario	55
4.2.7.5. Insertar imagen	55
4.2.8. Diagrama de clases	56
5. PRUEBAS Y MÉTRICAS DE CALIDAD	57
5.1. PRUEBAS PARA EL RECONOCIMIENTO DE LAS ESPECIES DE COPÉPODOS	57
5.2. MÉTRICAS DE CALIDAD ORIENTADAS A OBJETOS DEL PROTOTIPO	58
5.2.1. Tamaño de clase	59
5.2.2. Acoplamiento entre clases objetos	59
5.2.3. Carencia de cohesión en los métodos	59
5.2.4. Respuesta para una clase	60
6. CONCLUSIONES Y RECOMENDACIONES	61
6.1. ESTADO DE LOS OBJETIVOS	61

6.2. ESTADO DE LA HIPÓTESIS	62
6.3. CONCLUSIONES	62
6.4. RECOMENDACIONES	62
6.6 TRABAJOS FUTUROS	62
7. BIBLIOGRAFÍA	64
ANEXO A: Glosario	66
ANEXO C: Árbol de Objetivos	71
ANEXOS B: Árbol de Problemas	70



ÍNDICE DE FIGURAS

Figura 2.1: Vista dorsal de un copépodo	10
Figura 2.2: Vista ventral del copépodo	10
Figura 3.1: Estructura de una neurona biológica	21
Figura 3.2: Modelo de una neurona artificial	24
Figura 3.3: Funciones de activación	27
Figura 3.4: Pulsos y potencial codificado de una señal de salida de una neurona.	28
Figura 3.5: Arquitectura general de una red de retropropagación	35
Figura 4.1: Descripción del sistema	43
Figura 4.10: Diagrama de secuencia “insertar clave”	54
Figura 4.11: Diagrama de secuencia “reconocer imagen”	55
Figura 4.12: Diagrama de secuencia “almacenar resultado”	55
Figura 4.13: Diagrama de robustez “insertar clave”	56
Figura 4.14: Diagrama de robustez “recomocer imagen”	57
Figura 4.15: Diagrama de robustez “almacenar resultado”	58
Figura 4.16: Diagrama de robustez “registrar usuario”	59
Figura 4.17: Diagrama de robustez “insertar imagen”	59
Figura 4.18: Diagrama de clases	60
Figura 4.2: Modelo de la Red Neuronal	44
Figura 4.3: Interfaz del autenticador	45
Figura 4.4: Interfaz principal	46
Figura 4.5: Interfaz de reconocimiento de copépodos	47
Figura 4.6: Interfaz copépodos reconocidos	48
Figura 4.7: Casos de uso del sistema Sinerco	49
Figura 4.8: Diagrama de secuencia “insertar clave”	53
Figura 4.9: Diagrama de secuencia “registrar usuario”	54

ÍNDICE DE TABLAS

Tabla 1.1: Análisis de costo-beneficio del reconocimiento de las especies de copépodos	6
Tabla 4.1. Datos usados en la red neuronal	40
Tabla 5.1: Resultados de la prueba para el reconocimiento de copépodos.....	61
Tabla 5.2: Resultados de la prueba para el reconocimiento de copépodos.....	62
Tabla 5.3: Tamaño de clase	63
Tabla 5.4: Acoplamiento entre clases objeto (ACO).....	63
Tabla 5.5: Carencia de cohesión en los métodos (CCM)	64
Tabla 5.6: Carencia de cohesión en los métodos (RPC).....	64

ÍNDICE DE ALGORITMOS

Algoritmo 4.1: Retropropogación Copépodos.....	41
--	----



1. MARCO REFERENCIAL

Resumen

Este capítulo constituye el primer paso para afrontar el problema, aquí se define el objetivo principal del presente documento y se muestra la importancia del mismo. Se incluyen los trabajos previos en el área, los alcances, los límites y la forma en la que se realizará el reconocimiento de copépodos.

1.1. INTRODUCCIÓN

Los microcrustáceos del orden copépodos son organismos pequeños, generalmente entre 1 y algo más de 5 milímetros, aunque algunas especies pueden llegar a los 2 centímetros y otras parasitas a los 32 centímetros. Su color suele ser transparente, aunque abundan las formas rojas, anaranjadas y azuladas; sin embargo la importancia ecológica del grupo es muy grande. Muchos copépodos están confinados a habitats salobres¹ y marinos y solo una pequeña fracción viven en aguas continentales². Algunos grupos habitan ambientes de transición, siendo encontrados en el humus³, musgos y bromeliáceas.

Los copépodos son importantes presas para pequeños carnívoros especialmente larvas de peces, estos presentan un ciclo y metabolismo acelerado y se alimentan principalmente de residuos y bacterias; así muchas especies en parte se independizan de la producción autotrófica⁴ y juegan un rol importante en la producción de ciclos (Del Castillo, 1992).

En el lago Titicaca y en el lago Poopó, como en cualquier otra superficie acuática existen especies pertenecientes a la clase microcrustácea, dichas especies son esenciales para mantener el equilibrio del ecosistema en la piscicultura.

Es un hecho que el área de biología se ha visto en los últimos años ligada a la informática más específicamente al área de la inteligencia artificial, donde ha encontrado la forma de automatizar ciertos procesos, para brindar soluciones tempranas. En el presente trabajo se plantea las bases para el desarrollo de un sistema inteligente basado en redes neuronales para el reconocimiento y clasificación de especies de copépodos del lago Titicaca y el lago Poopó, determinando como consecuencia los grados de equilibrio ecológico pertinentes.

1.2. ANTECEDENTES

El lago Titicaca y el lago Poopó son objeto de varios estudios, por las características particulares que presentan, principalmente los parámetros físico-químicos, morfométricos⁵ diferentes y aspectos biológicos. Aspectos relacionados con las fluctuaciones de clima y nivel de agua provocan grandes

¹ Que contiene mucha sal o tiene sabor de sal.

² Alrededor de 2000 especies han sido descritas para este ambiente.

³ Este y otros términos biológicos se encuentran en el Anexo A: Glosario.

⁴ Él mismo produce sus alimentos para su existencia.

⁵ De la palabra morfometría, medición de las formas del relieve del suelo.

variaciones en la composición del ecosistema; la fauna de los lagos ha sido objeto de varias investigaciones, entre ellas los copépodos, como parte de los microcrustáceos.

Los copépodos encontrados en el lago Poopó, pertenecen al género *Boeckella*⁶. Este género incluye 38 especies de amplia distribución en Australia, Nueva Zelanda, Sud América y la porción subantártica que comprende la zona helada austral⁷. El investigador Bayly en 1992 en un trabajo sobre la fusión del género *Boeckella* y *Pseudoboeckella*, aún sin definirse, y en una revisión de sus especies procedentes de América del Sur e islas subantárticas reportó la presencia de *Boeckella poopuensis* en el lago Poopó descrita por primera vez por Kiefer en 1928 (Ramos, Dávila & Pinto, 2006).

Los primeros estudios sobre el zooplancton del lago Titicaca fueron realizados por investigadores que trabajaron con el material colectado por misiones itinerantes. Así, en 1939, De Beauchamp determina seis especies de rotíferos y en 1995, Harding realiza un estudio sobre los cladóceros y copépodos con las colecciones efectuadas por la expedición Percy Salden en 1937 (Pinto, 1991).

Posteriormente, Kiefer en 1957 efectúa una revisión más detallada de los copépodos con la descripción de nuevas subespecies y en 1967, Ueno realiza un trabajo general sobre el zooplancton del Huiñaimarca, parte boliviana, tomando en cuenta copépodos, cladóceros y rotíferos. Se indican las características taxonómicas y la repartición geográfica de algunas especies. Richerson y su equipo en 1977, en un estudio sobre el Lago Mayor⁸, consideran por primera vez el aspecto biomasa de los doblamientos tanto para el fitoplancton como para el zooplancton y determinan las variaciones cuantitativas estacionales de algunas especies. Pawlety en 1982 y 1983 analiza la repartición del zooplancton en el Lago Mayor respecto a los nutrientes presentes. Moreno en 1983 efectúa un estudio cuantitativo del plancton en la zona pelágica del Lago Mayor y determina la abundancia de los microcrustáceos y rotíferos en un transecto frente a las bahía de Puno, Perú.

Haney y Trout en 1985 realizan experimentos en el hábitat natural y en laboratorio sobre los hábitos alimenticios de copépodos y cladóceros con partículas seleccionadas del Sestón y de *Chlorella* inoculadas con carbono 14. En 1987 y 1988, Repelin determina la abundancia espacio temporal del zooplancton en la parte boliviana del lago relativa a copépodos, cladóceros y larvas nauplios; se realiza mapas de repartición del zooplancton tanto para el Lago Mayor como para el Lago Menor⁹ y analiza, también en el Huiñaimarca, las migraciones de algunos grupos (Pinto, 1991).

En la Unidad de Limnología del Instituto de Ecología, perteneciente a la carrera de Biología, Facultad de Ciencias Puras y Naturales de la Universidad Mayor de San Andrés, se estudia el zooplancton, dicha unidad fue creada con el objeto de conocer el funcionamiento de los ecosistemas acuáticos desde el punto de vista de la caracterización y diversidad de fauna y flora de toda Bolivia, asociado a las condiciones físicas y químicas del medio. Uno de los mayores objetivos de la unidad de limnología es ayudar a elaborar, con las autoridades gubernamentales, las políticas de conservación de la riqueza natural boliviana.

Las redes neuronales artificiales (RNA), han encontrado muchas aplicaciones exitosas en la visión artificial, en el procesado de señales e imágenes, reconocimiento del habla y de caracteres, sistemas

⁶ Especie de Copépodo, que se caracteriza por habitar generalmente en aguas dulces.

⁷ Del polo o del hemisferio sur.

⁸ Parte superior del Lago Titicaca.

⁹ Parte inferior del Lago Titicaca.

expertos, análisis de imágenes médicas, control remoto, control de robots, inspección industrial y exploración científica (Hilera & Martínez, 1995). Con los antecedentes mencionados es posible aplicar las redes neuronales a la clasificación de las especies de copépodos y determinar los grados de equilibrio ecológico, tomando en cuenta las capacidades de aprendizaje y clasificación de respuestas de las RNA.

La Unidad de Limnología cuenta con investigadores en Biología, laboratorios y equipamiento especializado para desarrollar trabajos de investigación científica. El Área de Zooplancton, tiene almacenadas muestras de plancton recolectadas de los lagos Titicaca y Poopó, esto permitirá la aplicabilidad de las redes neuronales en el reconocimiento de patrones, trabajando con las imágenes fotográficas que se tomaran de las muestras existentes y se obtendrán nuevas imágenes fotográficas bajo un procedimiento para adquiridas.

1.3. PROBLEMA DE INVESTIGACIÓN

El zooplancton está constituido por diversos grupos de invertebrados, entre ellos se encuentran los rotíferos y los microcrustáceos (copépodos y cladóceros).

Dentro de la red alimentaria de un lago, el zooplancton constituye el principal eslabón alimenticio del cual dependen los peces, sobre todo en su etapa inicial de desarrollo y que frecuentemente puede tener un impacto sobre las poblaciones zoopláctónicas es decir que su ausencia podría dejar sin comida a los peces, lo que provocaría su extinción.

De la misma forma que el fitoplancton, el zooplancton, es decir, microcrustáceos y rotíferos, tienen un valor potencial como indicadores del estado trófico de un cuerpo de agua, ya que responden rápidamente a cambios ambientales. De acuerdo con el investigador Infante en 1988, la desaparición de ciertas especies suele ser un indicador de las variaciones de las características de un lago midiendo el grado de eutrofización (Rocha, 2002).

1.3.1. Planteamiento del problema

El zooplancton es parte del ecosistema y su estudio sirve para conocer el funcionamiento, calidad y productividad del mismo ambiente, de esta forma el conocimiento del ecosistema ya sea estadístico o cognitivo, sirve para plantear políticas para la conservación de la biodiversidad del ecosistema en función al equilibrio ecológico.

En general las comunidades zoopláctónicas bolivianas no fueron estudiadas de manera sistemática en términos de taxonomía, ecología y distribución, habiéndose reportado algunos aportes para el lago Titicaca y una de sus áreas de influencia como es el lago Poopó, dichos aportes fueron mostrados en el punto 1.2. Antecedentes.

El tiempo requerido para el reconocimiento de copépodos es relativo, pero generalmente tarda de un día hasta 3 semanas y los factores que determinan dicho reconocimiento son: el conocimiento previo que el experto tenga del espécimen, el trabajo manual del experto, el estado de la muestra y las claves dicotómicas¹⁰ que se utilizan para el reconocimiento de los copépodos.

¹⁰ De dicotomía, que es la división de un concepto o una materia teórica en dos aspectos, especialmente cuando son opuestos o están muy diferenciados entre sí. Ejemplo: Respondiendo a la pregunta ¿El espécimen presenta anténulas?, la respuesta sólo puede ser Si ó No.

Tener almacenado el conocimiento de investigaciones previas facilita nuevos estudios ya que solamente se realizan esfuerzos necesarios para identificar especies ya clasificadas, lamentablemente la información que se tiene respecto a los copépodos esta desconcentrada y afecta económicamente, ya que se realizan nuevas investigaciones sin tomar en cuenta las investigaciones anteriores, lo que implica nuevas recolecciones en los lagos, nuevos procesos de almacenamiento de las recolecciones, y gasto de energía eléctrica con el microscopio para revisar las muestras.

1.3.2. Formulación del problema

El proceso de clasificación de copépodos se encuentra condicionado por las características morfológicas del mismo y por los factores que intervienen en el proceso de reconocimiento de la especie, además la información de la misma es limitada y desconcentrada para nuevos estudios de limnología en distintas partes de Bolivia¹¹.

1.3.3. Problemas específicos

1. Dificultad en la observación del copépodo debido a su tamaño natural.
2. Demora en el tiempo de clasificación debido a la carencia de expertos.
3. Clasificaciones erróneas de especies de copépodos, porque el investigador se ve afectado por factores subjetivos como: cansancio, capacidad visual, falta de atención.
4. Dificultad en el reconocimiento de especies debido a la incompletitud de la especie.
5. Análisis incompleto de la especie de copépodo provocado por imágenes con ruido y con baja resolución.

1.4. OBJETIVOS

1.4.1. Objetivo general

Clasificar las especies de copépodos existentes en los lagos Titicaca y Poopó mediante un prototipo computarizado basado en redes neuronales utilizando las imágenes fotográficas de los estudios realizados sobre este orden¹².

1.4.2. Objetivos específicos

1. Obtener imágenes claras de las especies de Copépodos de los lagos Titicaca y Poopó mediante cámaras digitales¹³ de microscopios con alta resolución.
2. Evitar consultar las claves de identificación para la clasificación de copépodos, ya que la red neuronal solo necesita trabajar con las imágenes fotográficas.
3. Reducir el error de la clasificación de especies de copépodos, mediante las imágenes fotográficas tomadas del mismo.
4. Utilizar la capacidad de generalización de las redes neuronales artificiales para el reconocimiento de las especies de copépodos incompletas.
5. Obtener parámetros de entrada para el entrenamiento de la red neuronal aplicando filtros adaptativos y estandarizando el tamaño de las imágenes.
6. Construir el modelo de red neuronal artificial para el reconocimiento de copépodos.

¹¹ Un detalle complementario se encuentra en el Anexo B: Árbol de Problemas.

¹² Un detalle complementario se encuentra en el Anexo C: Árbol de Objetivos

¹³ Son cámaras digitales que se aplican a microscopios para la obtención de imágenes.

7. Construir el prototipo con base en el modelo establecido.
8. Evaluar el prototipo mediante métricas de calidad.

1.5. ALCANCES

El prototipo basado en redes neuronales artificiales a ser desarrollado, permitirá al investigador del área de zooplankton de la Unidad de Limnología:

1. Reconocer y clasificar a los copépodos según sus distintas especies que se presentan en los lagos Titicaca y Poopó.
2. Realizará procesos de filtrado de imágenes fotográficas para obtener parámetros de entrada necesarios para el entrenamiento y funcionamiento de la red neuronal artificial.
3. Almacenara los resultados obtenidos para su posterior utilidad.

1.6. LÍMITES

1. El prototipo se limita a reconocer y clasificar especies de copépodos de los lagos Titicaca y Poopó, utilizando imágenes fotográficas tomadas del microscopio electrónico.
2. El software será desarrollado independientemente a la plataforma utilizada. Las pruebas del sistema se realizarán en un ambiente real, ya que la Unidad de Limnología cuenta con datos reales.

1.7. HIPÓTESIS

Es posible identificar las especies de copépodos existentes en el lago Titicaca y Poopó mediante el reconocimiento de imágenes fotográficas tomadas del microscopio electrónico y procesar las mismas a través de una red neuronal artificial con una capacidad de reconocimiento superior al 90 %.

1.8. JUSTIFICACIÓN DEL TEMA

1.8.1. Justificación metodológica

Se justifica metodológicamente al uso del método científico, el cual permitirá obtener conocimiento nuevo a través del conocimiento existente. En el desarrollo del prototipo el método de la ingeniería del software orientada a objetos indica los pasos correctos para obtener productos con calidad, el prototipo computarizado será desarrollado a partir de dichas metodologías.

1.8.2. Justificación práctica

El reconocimiento de imágenes mediante redes neuronales es sin duda una tecnología que está siendo ampliamente utilizada en el campo de la medicina, seguridad, biología, etc. Es importante conocer su funcionamiento para seguir ampliando el conocimiento de esta tecnología y la aplicación de este en nuevas investigaciones.

El prototipo computarizado será desarrollado bajo los lineamientos de la ingeniería del software con el modelo de proceso evolutivo incremental, este prototipo presentará calidad y optimizará el tiempo de identificación y clasificación de los microcrustáceos de orden copépodos, colaborando con la simplificación de las tareas del investigador.

1.8.3. Justificación económica

Se realizó el análisis de costo-beneficio en la Unidad de Limnología y se estimaron costos del prototipo de acuerdo a las características descritas en la Tabla 1.

Tabla 1.1: Análisis de costo-beneficio del reconocimiento de las especies de copépodos

Experto de limnología		Prototipo computarizado	
Costo por identificación de especies	195,00 Bs.	Costo por identificación de especies	0,00 Bs.
Uso de equipo:		Uso de equipo:	
Microscopio (15 horas de consumo eléctrico)	108,00 Bs.	Microscopio (2 horas de consumo eléctrico)	15,00 Bs.
Equipo de disección	50,00 Bs.	Equipo de disección	50,00 Bs.
		Computadora	35,00 Bs.
		Cámara digital	45,00 Bs.
Materiales:		Materiales:	
Alcohol	1,60 Bs.	Alcohol	1,60 Bs.
Formol	1,80 Bs.	Formol	1,80 Bs.
Acido láctico ¹⁴	14,00 Bs.	Acido láctico	22,00 Bs.
COSTO TOTAL	370,40 Bs.	COSTO TOTAL	170,40 Bs.

La utilización del prototipo computarizado según el análisis costo-beneficio es notablemente menor al reconocimiento manual. El porcentaje deducido del costo total asociado del prototipo computarizado es del 46% por lo que el desarrollo del prototipo se justifica en términos económicos.

1.8.4. Justificación social

El deterioro del ecosistema es un problema que debería preocupar a toda la población en general, ya que este impacto afecta directamente a la sociedad y al medio ambiente; los copépodos son relevantes porque constituyen parte del eslabón alimenticio del hombre y lo más importante es que ayudan a la investigación del entorno ecológico ya que se trata de indicadores biológicos ampliamente aceptados.

Este trabajo beneficia al investigador del área de zooplancton de la Unidad de Limnología y a la sociedad consumidora de pescado debido a que los copépodos son el alimento del alimento que consume el ser humano.

1.8.5. Justificación técnica

La justificación técnica se encuentra en este trabajo debido a que se cuenta con el equipamiento suficiente para el estudio de los copépodos. Se obtendrán imágenes con una cámara digital, cuando el microscopio se encuentra enfocando al copépodo, después estas imágenes serán trasladadas a la

¹⁴ Este ácido se utiliza para decolorar el exoesqueleto del copépodo.

computadora, para ser procesadas con la red neuronal, la cual se encargará de reconocer y clasificar al copépodo en un determinado grupo etiquetado como especie.

1.9. ASPECTOS METODOLÓGICOS

1.9.1. Tipo de estudio

Este trabajo se basa en fundamentos de redes neuronales para el reconocimiento de patrones de las distintas especies de copépodos, la investigación es de tipo teórica y experimental, por que se realizara el marco teórico respectivo y se aplicara los conocimientos en la construcción de un prototipo que será utilizado para contrastar la hipótesis.

1.9.2. Método de investigación

Se utiliza la metodología de investigación científica **hipotético deductiva**, siguiendo los lineamientos establecidos por Mario Bunge (1997), de la siguiente manera:

- a) **Observación.** Se realizará el relevamiento y la teorización de las necesidades y falencias de la identificación y clasificación de las especies de copépodos. Incluyendo el análisis de las redes neuronales para el reconocimiento de patrones tomando en cuenta el preprocesamiento de imágenes.
- b) **Planteo de la hipótesis.** Es posible identificar las especies de copépodos existentes en los lagos Titicaca y Poopó mediante el reconocimiento de imágenes fotográficas tomadas del microscopio electrónico y procesar las mismas a través de una red neuronal artificial con una capacidad de generalización superior al 90 %.
- c) **Diseño de la aplicación.** Se procederá al diseño de una red neuronal para el reconocimiento de patrones, en este caso patrones de los diferentes tipos de copépodos de los lagos Titicaca y Poopó.
- d) **Casos de prueba.** Se insertarán los postulados teóricos de la ingeniería del software y luego con el prototipo terminado se evaluará la calidad con un conjunto de casos de prueba de caja negra, por que estas pruebas se llevarán a cabo sobre la interfaz del software.
- e) **Conclusiones.** Se redactará un capítulo final de la investigación relacionada con el desarrollo de un modelo de red neuronal para la clasificación de copépodos.

Para la implementación del modelo de red neuronal, útil para la identificación y clasificación de copépodos, se utilizará el método de la ingeniería del software. Siguiendo con los pasos del análisis, diseño, codificación y prueba (Pressman, 2006). Para el diseño de la red neuronal se consideran: (1) el método del desarrollo de redes neuronales propuesta por Eliasmith (2003); (2) el preprocesamiento de imágenes para encontrara el número de entradas óptimas para la red neuronal; (3) y la mejora de la generalización de la red neuronal mediante las técnicas de parada temprana y regularización.

2. COPÉPODOS

Resumen

En este capítulo se describe de manera detallada la morfología externa e interna de los copépodos, además se resalta la importancia de los mismos en la cadena trófica y como la base del modelado para la solución del presente trabajo.

2.1. INTRODUCCIÓN

Los copépodos constituyen el mayor grupo de pequeños crustáceos, ya que incluyen 8500 especies la mayoría marinas, aunque algunas son de agua dulce y otras son terrestres. Son generalmente planctónicas, representando un eslabón de gran importancia en las cadenas tróficas marinas, ya que se alimentan de fitoplancton y son la base de la alimentación de muchos peces; han sido bastante estudiados como reguladores de las poblaciones de fitoplancton al representar el principal constituyente del zooplancton marino (Asturnatura, 2007) (Björnberg, 2007).

Por el hecho de constituir el integrante más numeroso del plancton de red, los copépodos fueron y son estudiados muy activamente, existiendo monografías enteras dedicadas a una sola especie como, por ejemplo, el trabajo de Marshall y Orr de 1972 sobre *Clanes finmarchicus*, alimento principal del arenque en el Atlántico Norte. En el Atlántico Sur hay otras especies sumamente importantes como alimento de los peces planctófagos, que se verán mas adelante. Esta importancia, debida a su numerosidad, hace que los copépodos sean un permanente objeto de estudios físicos, químicos, biológicos, geográficos, ecológicos y otros (Björnberg, 2007).

En los puntos posteriores se verá al copépodo desde el punto de vista biológico, su morfología, su descripción física, es decir se los conocerá a fondo, para entender la importancia de esta clase en la cadena trófica y para tener una mejor idea de cómo serán las imágenes fotográficas y así aplicar los filtros necesarios.

2.2. MORFOLOGÍA.

2.2.1. Morfología externa

Son de pequeño tamaño, generalmente entre 1 y algo más de 5 milímetros, aunque algunas especies pueden llegar a los 2 centímetros y alguna parásita a los 32 centímetros. Su color suele ser transparente, aunque abundan rojas, anaranjadas y azuladas (Asturnatura, 2007).

La clasificación de los copépodos se basa en su anatomía externa. El cuerpo esta, usualmente, integrado por tres regiones: (1) la cabeza o céfalo, con 6 segmentos fusionados; (2) el tórax y (3) el abdomen, este ultimo desprovisto de apéndices. La cabeza y el tórax constituyen la parte anterior denominada cefalotórax o cefalosoma, en cuya superficie ventral se encuentran 5 pares de apéndices torácicos. En la región anterior de la cabeza puede existir lentes oculares dorsales y ventrales, una cresta y un rostro.

Los 6 pares de apéndices son: las anténulas (unirramosas); las antenas, ramificadas en un exo¹⁵ y un endopodito; las mandíbulas, provistas de una gnátobase y palpos¹⁶ birramosos; las maxílulas o primer par de maxilas; las maxilas propiamente dichas o segundo par de maxilas y el primer par de maxilípedos, siempre unirramosos. Los maxilípedos o segundos maxilípedos son también unirramosos y aun cuando funcionan como elementos auxiliares para la captura del alimento, son considerados como el primer par de patas torácicas por algunos autores.

La abertura bucal, situada entre los puntos de inserción de las mandíbulas, esta cubierta anteriormente con un labro¹⁷ y posteriormente, posee una elevación cuticular o labio inferior. El tórax o metasoma está integrado, originalmente, por 6 segmentos. El primero de los cuales se funde con la cabeza para constituir el cefalosoma. Cada uno de los restantes o torácicos lleva un par de apéndices birramosos, esencialmente constituidos por un coxópodo, un coxopodito o base 1, un basípodo, un basipodito, o base 2, un exópodo y un endópodo. El quinto par, el último en la mayoría de los copépodos y que puede sufrir reducciones considerables y hasta desaparecer totalmente o hipertrofiarse, es utilizado sistemáticamente para diferenciar los sexos. Los calánidos machos utilizan este par para transferir el espermatóforo, durante la cópula, al segmento genital de la hembra; de allí que cuando existe la hipertrofia mencionada, está sólo se observa en los machos. En las hembras, por el contrario, estos apéndices son reducidos, atrofiados y hasta ausentes.

Los ciclopoideos y harpaticoideos tienen, a veces, un sexto par de patas muy reducido y la articulación móvil principal del cuerpo está ubicada entre el cuarto y quinto somitos o segmentos torácicos. El término “urosoma¹⁸” se utiliza para designar, en estos dos órdenes, los dos últimos segmentos torácicos más los abdominales. En calanoida la articulación somática móvil principal esta ubicada entre el quinto segmento torácico y el primero abdominal separando, de esta manera, la parte anterior más ancha del cuerpo de la posterior, más estrecha. El primer somito abdominal es el genital en las hembras (también considerando, por algunos autores, como el sexto segmento torácico y por otros como los dos primeros abdominales fusionados) y lleva los gonoporos en el ventro¹⁹, en calanoida y harpaticoida, y en el dorso, en ciclopoidea. En los dos primeros los poros genitales están cubiertos por una placa quitinosa²⁰: el opérculo astral o placa genital. El ultimo segmento abdominal o telson²¹ es el anal y termina en 2 ramas caudales o furca paralelas, o más o menos divergentes y articulaciones con el segmento caudal (Björnberg, 2007).

En el año 2007, para la diferenciación entre especies suele tomarse en consideración la distribución de los órganos intersegmentarios, las microcerdas y microfasetas de los órganos sensoriales o sensilas y de los poros glandulares visibles con el microscopio electrónico de barrido o con el uso de técnicas especiales (Björnberg, 2007). Las partes de los copépodos con la vista dorsal y la vista ventral son descritas en la figura 2.1. y 2.2.

¹⁵ Exo, estructura de localización externa.

¹⁶ Apéndice articulado y movable que en forma y número diferentes tienen los insectos, las arañas, los crustáceos y otros invertebrados alrededor de la boca para palpar y sujetar lo que comen.

¹⁷ Labio superior de la boca de un insecto.

¹⁸ Cuerpo posterior.

¹⁹ Barriga, vientre

²⁰ Quitinoso, compuesto de quitina que es una sustancia blanca de tipo córneo que se encuentra en el esqueleto externo del cangrejo, la langosta y muchos insectos, además en las estructuras internas de algunos otros invertebrados, y en algunos hongos, algas y levaduras.

²¹ Telson, el último segmento en el abdomen en los crustáceos.




Figura 2.1: Vista dorsal de un copépodo
Fuente: (Asturnatura, 2007)




Figura 2.2: Vista ventral del copépodo
Fuente: (Asturnatura, 2007)

Las tres familias más destacadas son las correspondientes a los ciclopoideos, calanoides y harpaticoides; las demás familias contemplan organismos de vida marina o formas parasitas:

1. **Ciclopoides:** Esta especie generalmente carnívora tiene una longitud de 0.6 a varios milímetros, tiene un cefalotórax redondeado, usualmente está separado del abdomen, presenta anténulas más cortas que en la especie calanoida; setas de la furca de diferente longitud.
2. **Calanoida:** Esta especie generalmente herbívora tiene una longitud de 1 a varios milímetros, tiene un cefalotórax redondeado pero alargado, claramente separado del margen del abdomen; presenta anténulas largas; setas furcales de igual longitud.
3. **Harpaticoides:** Esta especie generalmente detritívora tiene una longitud menor de 1 milímetro, con un cuerpo alargado y delgado además de anténulas muy cortas y sin una visible separación entre el tórax y el abdomen. Mayormente viven en lugares marinos o de aguas salinas, pocas especies habitan en agua dulce y algunas pueden ser encontradas en musgos, humus y bromeliáceas.

El cuerpo de los copépodos está compuesto de segmentos de tipo anillados: que corresponden a los metámeros o somitas. Cada uno de ellos comprende una parte dorsal (tergito) y una vertical (esternito), fusionados por los lados extremos y los apéndices pares están adheridos al esternito.

El extremo de los segmentos presenta en su unión con el otro segmento una hialina que puede ser puntiaguda o dentada; estando los segmentos fusionados por una delgada membrana de articulación (Del Castillo, 1992).

El cuerpo presenta tres regiones típicas: el cefalotórax, tórax y el abdomen.

Según Del Castillo (1992) los apéndices que se presentan son:

1. Un par de Antenas: estas son siempre uniramosas y tienen de 6 a más de 25 segmentos. Los machos adultos presentan una anténula en la especie Calanoida o ambas anténulas en las especies Ciclopoida y Harpaticoida, son geniculadas y además son usadas para agarrar a la hembra durante la cópula.
2. Un par de Antenas: estas son uniramosas en la especie Ciclopoda; biramosas en la especie Calanoida y uniramosas con exopodito rudimentario en la especie Harpaticoides.
3. Un par de Mandíbulas: que son apéndices alimenticios.
4. Un par de Maxíbulas: que son accesorios alimenticios.
5. Un par Maxilas: que son accesorios alimenticios.
6. Un par de Maxilipodios: estos son considerados como los apéndices originales de los primeros toraxópodos y son adaptados para la alimentación.
7. Toraxópodos: estos son típicos apéndices o patas nadadoras, usadas para la locomoción; biramosos, con membrana de conexión. Cada parte compuesta de un prototipo basal para el coxopodito y el basipodito, sustentando un exopodito y endopodito. El toraxópodo rudimentario, es usado para la copulación; de diferente conformación en la especie calanoida y es de importante criterio para la determinación en la especie ciclopoida. El toraxópodo esta presente en ciclopoideos y harpaticoides, fuertemente desarrollado en los machos y reducido en las hembras.

2.2.2. Morfología interna

Es relativamente sencilla. La musculatura es estriada y está incluida dentro del endoesqueleto. Este último consiste en dos endoesternitos ventrales tendinosos en la región anterior, a los cuales se fijan los músculos de las antenas y piezas bucales, y en numerosas protuberancias quitinosas internas que sirven de soporte a los músculos de los apéndices. De la superficie ventral se proyectan dos delgadas barras quitinosas que atraviesan los músculos ventrales y longitudinales que son flexores del cuerpo, y los transversales y oblicuos movilizan los apéndices bucales y las patas. Hay además, músculos menores que sustentan el corazón que contraen y distienden²² el pericardio.

El tubo digestivo cuenta con un esófago (estodomeo) musculosos, un estomago y un intestino recto (proctodeo) que recorre todo el urosoma y desemboca en el ano. La forma del estomago puede ser utilizada para distinción de las especies de *Eucalamus*. Una vesícula de aceite de reserva se ubica dorsalmente al tubo digestivo. Hay un corazón dorsal medio, que a veces puede faltar. No hay vasos sanguíneos. El sistema excretor consta de las glándulas maxilares y dermales.

Los elementos del sistema nervioso son un par de ganglios cerebrales, un anillo periesofágico y una cadena ganglionar ventral. Además, existen fibras nerviosas gigantes que inervan²³ los músculos de las anténulas y de las patas, permitiendo movimientos de evasión rápidos. Los órganos de los sentidos están representados por los ojos, cerdas sensoriales y órganos frontales. Los ojos, cuando existen, pueden estar representados por uno solo (mediano), dos (dorsales), o tres (dos dorsales y uno ventral). Su forma es ampliamente variable; a veces son muy grandes y conspicuos extendiéndose sobre todo el metasoma y provistos de lentes cuniculares, como, por ejemplo, en *Corycaeus* pero también pueden ser reducidos, como en *Calanoida*.

Los sexos son separados. La hembra tiene un ovario central dorsal con dos oviductos laterales que desembocan en los gonoporos. En los machos suele observarse la desaparición de uno de los conductos diferentes de manera que el aparato reproductor se torna asimétrico. Los espermatozoides maduros son almacenados dentro de los espermatóforos secretados por las vías genitales. Durante el acoplamiento el macho, generalmente por medio de su quinta pata (calanoida), los fija sobre o en la vecindad de los gonoporos de la hembra. A cada lado de estos últimos hay una espermateca donde se depositan los espermatozoides; la inclinación de estas espermatecas (también llamadas receptáculos seminales) con relación al eje mayor del cuerpo constituye un importante carácter sistemático en varios géneros. Ambos sexos pueden ser parecidos o puede también haber un considerable dimorfismo sexual. Para la clasificación de Copépoda el urosoma es de importancia; si el primer segmento es mayor y evidencia estructuras internas y externas el ejemplar es una hembra adulta. En caso contrario, deben buscarse los espermatóforos. En los machos de *Calanoida* estos se ubican en el cefalotórax, y en *Cyclopoida* en un segmento del urosoma. Los copépodos jóvenes, carentes de estas estructuras, son difíciles de clasificar (Björnberg, 2007).

2.3. REPRODUCCIÓN Y DESARROLLO

Los copépodos representan en el zooplancton especies más adaptadas a los ambientes estables y son capaces de realizar una reproducción eficiente. A pesar de que en los copépodos hay una variabilidad mucho mayor que en los cladóceros, tienen, a diferencia de estos últimos, una tasa de reproducción menor debido a que está es de tipo sexual y un tiempo de generación más largo (de 3

²² Estirarse por tensión (los tejidos o ligamentos de una articulación) sin llegar a romperse.

²³ Transmitir estímulos nerviosos a una zona del organismo.

meses a 1 año). También la captura de alimento es diferente, ya que pueden seleccionar las partículas de forma activa.

Cladóceros y copépodos responden de forma distinta, de acuerdo con sus estrategias, a las condiciones ambientales, de tal manera que la dominancia de uno u otro grupo estará relacionada de forma más o menos directa con la estabilidad del sistema (Armengol, 1980).

La fecundación es cruzada y probablemente también ocurra partenogénesis. Durante la copula el macho asegura a la hembra de sus antenas geniculadas, piezas bucales o patas modificadas, aun con una de las del quinto par y transfiere el espermatóforo con la otra quinta pata o flexionando su urosoma sobre el de la hembra. Los espermatozoides, almacenados en los receptáculos seminales femeninos, van fecundando los óvulos a medida que éstos descienden por los oviductos y salen por el gonoporo. Los huevos pueden ser liberados por uno o, en otros casos, quedan pegados entre sí por una sustancia gelatinosa, formando una o dos **estructuras** semejantes a racimos de uvas adheridas al segmento genital²⁴.

Luego de un determinado lapso, que puede variar de horas a días, las larvas nauplius eclosionan; estas tienen 3 pares de apéndices funcionales y son totalmente diferentes a los adultos. Normalmente la metamorfosis tiene lugar después de 5 mudas y aparece el primer copépodo: copépodo juvenil parecido al adulto. El ciclo completo está integrado por 6 estadios naupliares, 5 copepoditos y finalmente, uno adulto. Las dos primeras nauplius se denominan ortonauplius y carecen de segmentación; las demás (metanauplius) ya tienen segmentación y más de tres pares de apéndices.

Frecuentemente se observa la reducción de la cantidad de estadios naupliares: *Pseudodiaptomus* tiene 5 y algunas especies criófilas como, por ejemplo, *chiridius armatus*, solamente 4. La duración del ciclo completo varía de una especie a otra y puede abarcar desde una semana hasta más de un año. La cantidad de generaciones por año depende del hábitat de la especie. En aguas tropicales oceánicas la reproducción es continua durante prácticamente todo el año, mientras que en las interiores como, por ejemplo, los manglares, especies tales como *Pracalamus crassirostris* pueden reproducirse durante una parte del año y dejar de hacerlo en otra. En las regiones subantárticas y antárticas hay copépodos, como *Rhincalamus gigas*, con 2 generaciones anuales y otros, como *Calanoides acutus*, con solamente un máximo de hembras ovígeras por año (Björnberg, 2007).

2.4. MOVILIDAD Y NUTRICIÓN

Los movimientos de un copépodo están relacionados con tres tipos de actividades básicas: nutrición, locomoción y migración. Aquellos, a su vez, están en función del medio que habitan y del modo de vida. Los calanoides planctónicos, herbívoros u omnívoros, pastorean filtrando el alimento que aportan los remolinos provocados por el movimiento de las cerdas de las piezas bucales; estas producen de 600 a 2640 vibraciones por minuto, de manera tal que el animal se traslada lentamente hacia delante con el cuerpo casi vertical, o levemente inclinado. De esta manera las partículas alimenticias son acumuladas por las cerdas alrededor de la boca.

Los hipoplantónicos como, por ejemplo *Pseudodiaptomus*, fijan las anténulas al sustrato por medio de cerdas glandulares y hacen vibrar los palpos generando remolinos de agua que acumulan el alimento en la micromembrana formada por las cerdas y cerdulas de los apéndices bucales. El

²⁴ Son los llamados sacos ovígeros u ovisacos.

alimento así colectado es triturado por las gnatobases de las mandíbulas y forzado dentro de la boca por las cerdas masticatorias de las maxíbulas. Los géneros *Oithona* y *Acartia* se alimentan asiendo partículas de plancton por medio de las largas cerdas de las máxilas y maxilípedos que funcionan como espumaderas. Estos organismos no generan remolinos de agua; la locomoción se efectúa por medio de sucesivos impulsos hacia delante batiendo todas las patas hacia atrás. Entre los calánidos y ciclópodos también hay formas carnívoras predadoras. Los maxilípedos de *Euchaeta* y las maxilas de *Candacia* están armados con respectivos ganchos que utilizan a modo de pinzas para atrapar a sus presas, frecuentemente hasta 4 veces más grandes que el copépodo mismo. Numerosas especies de harpaticoida, cyclopoida y calanoida son raspadoras del fondo o comedoras de detritos y según algunos autores las de grandes profundidades y de aguas frías se alimentan, principalmente, de partículas orgánicas en suspensión.

De todo lo expuesto se evidencia que existe una correlación entre la forma de las piezas bucales y el tipo de alimentación, principalmente con el tamaño de las partículas ingeridas. Sin embargo, esta correlación no es rígida; estudios experimentales demostraron que especies típicamente herbívoras pueden, a falta de alimento vegetal, sustituirlo por alimento de origen animal, como por ejemplo, nauplii de otros crustáceos (Björnberg, 2007).

Carnívoros y herbívoros, constituyen niveles perfectamente diferenciados en la cadena alimentaria de la mayoría de los ecosistemas y como tales, junto con los productores primarios, son los grupos básicos en los que se estructura tróficamente una comunidad. Aunque el régimen alimentario de los crustáceos planctoncillos de las aguas continentales es fundamentalmente herbívoros, es frecuente la existencia de especies carnívoras. En los copépodos no existe una dependencia tan estricta con respecto al tipo de régimen alimentario. Los calanoides generalmente son herbívoros, lo mismo que los cladóceros, aunque a diferencia de estos no capturan el alimento de manera automática. Los ciclopoideos por la forma de capturar el alimento son predadores y realizan una selección activa del tamaño de las partículas. Los de mayor tamaño (1.5-2.5 milímetros) son exclusivamente carnívoros (comen copépodos, cladóceros, larvas de insecto, gusanos), y los más pequeños (0.5-1.5 milímetros) capturan preferentemente vegetales (algas, rotíferos y protozoos) (Armengol, 1980).

Según Björnberg en 2007 los ensayos *in Vitro* evidenciaron que la tasa de pastoreo es inversamente proporcional a la concentración de fitoplancton, la duración del experimento y la edad de los cultivos de fitoplancton utilizados; y que también existen diferencias sensibles entre la cantidad de comida ingerida por los diferentes estadios de desarrollo intra e interespecíficamente. Cada especie esta, además adaptada a un tipo de nutrición determinado: en líneas generales, las de aguas más ricas consumen diatomeas y las de las más pobres, dinoflagelados.

Algunos Harpaticoida bentónicos e hiperbénticos raspan la comida del fondo y, esporádicamente, pueden integrar el plancton. También las fases de vida libre de las especies parasitas pueden constituir elementos mero planctónicos. Los adultos de Monstrilloidea, por ejemplo, no poseen boca ni piezas bucales, sus adultos no se alimentan en absoluto y su permanencia en el plancton es apenas suficiente como para fecundar y poner los huevos, muriendo luego de la eclosión de los nauplii.

La locomoción en Calanoida ocurre como resultado del batir metacrónico (primero una y luego la otra), hacia atrás de las patas a modo de remos; ello provoca un fuerte impulso hacia adelante. Durante el desplazamiento las anténulas se doblan hacia atrás, a lo largo del cuerpo.

Los copépodos planctónicos tienen, además de movimientos locomotrices y de nutrición, otros migratorios. Las migraciones verticales del plancton pueden ser diarias, estacionales u ontogenéticas. El ascenso es activo y se realiza gracias al movimiento de las patas y el descenso, según algunos autores es pasivo, gravitacional.

Por último existe, en los copépodos pelágicos, un tipo de movimiento especial que difiere de los demás porque, en vez de consistir en el batir de la patas, es una serie de flexiones del abdomen hacia abajo y arriba. Este fenómeno fue observado en Corycaeidae por Barth en 1963. Es notablemente más lento que el de los otros copépodos y probablemente por este motivo, los *Corycaeus*, animales predadores, frecuentemente se observan cabalgando sobre sus víctimas, que generalmente son mucho mayores que ellos mismos. De esta manera las presas no solo les sirven de alimento, sino también de transporte (Björnberg, 2007).

2.5. COMPOSICIÓN QUÍMICA Y EXCRECIÓN

Debido a la descomunal importancia de los copépodos en las redes tróficas marinas se han realizado numerosos estudios de índole fisiológica y química sobre ellos. Principalmente en el Mar mediterráneo y Atlántico Norte, donde la planctología está más avanzada, algunos de los temas analizados fueron las necesidades alimentarias, respiración y excreción, calorimetría, contenido de grasas, lípidos, ácidos grasos, aminoácidos, proteínas, etc.

Se observan importantes variaciones ontogenéticas y estacionales de los contenidos lipídicos, proteicos y de agua y ajustadas correspondencias entre los compuestos grasos de Copepoda y aquéllos de sus predadores, los peces planctófagos.

Los productos de excreción consisten en amoníaco y fósforo inorgánico. Es interesante destacar que, al menos en algunas especies, la excreción depende de la concentración de fitoplancton; las excretas²⁵ del zooplancton en general, constituyen una importante fuente de productos aprovechables en el mar, hasta el punto que, a veces, existe una verdadera asociación donde las algas reciben los nutrientes excretados por el zooplancton (Björnberg, 2007).

2.6. UTILIDAD E IMPORTANCIA

2.6.1. Situación en las redes tróficas

Los copépodos son los consumidores primarios más numerosos de prácticamente todos los mares, océanos y lagos. También consumen detritos orgánicos y hasta petróleo derramado, constituyendo así un importante factor de limpieza en general y de las contaminaciones de este tipo en particular. A su vez constituyen el alimento primordial de numerosos peces planctófagos, también son consumidos por innumerables alevinos²⁶ y una gran cantidad de invertebrados, tanto planctónicos como bentónicos. Desde el punto de vista energético los copépodos, como herbívoros y detritívoros, desempeñan papeles primordiales en los diferentes lugares que habitan (Björnberg, 2007).

²⁵ Aminoácidos y otros compuestos.

²⁶ Pez joven.

2.6.2. Indicadores biológicos

Los copépodos y especialmente los grupos abundantes, sirven para caracterizar las masas de agua. También se han utilizado los copépodos como indicadores de áreas de afloramientos. El incremento de las densidades de algunas especies, significa la eutrofización de las aguas correspondientes (Björnberg, 2007).

2.7. DISTRIBUCIÓN

De acuerdo a Gilson en 1964 en la parte central de Los Andes sobre los bordes de Perú y Bolivia, a una altura de aproximada de 3800 metros sobre el nivel del mar, en el área conocida como Altiplano, una depresión en la parte norte esta ocupada por el lago Titicaca, el cual drena el río Desaguadero dentro el lago Poopó y los pantanos salinos que lo rodean.

La historia geológica del Altiplano se ha discutido por Moon en 1939 y por Newell en 1946. Por el inicio de la Miocena esas montañas, han sido formadas en la era Cretácea y Eocena. Hay razones para pensar que en la era Paleocena, el altiplano estaba solo a algunos metros sobre en nivel del mar y tenía una gran riqueza tropical de vegetación.

El primero, el lago Ballivián incluía lo que hoy en día se conoce como el Titicaca y Poopó; el segundo hace referencia al lago Minchin, que incluía solo la base del Poopó, pero el lago Titicaca probablemente existió con anterioridad (Gilson, 1964).

El lago Titicaca y el lago Poopó son objeto de varios estudios, por las características particulares que presentan, principalmente los parámetros físico-químicos, morfométricos diferentes y aspectos biológicos. Aspectos relacionados con las fluctuaciones de clima y nivel de agua provocan grandes variaciones en la composición del ecosistema; la fauna de los lagos ha sido objeto de varias investigaciones, entre ellas los copépodos, como parte de los microcrustáceos.

Los copépodos encontrados en el lago Poopó, pertenecen al género *boeckella*. Este género incluye 38 especies de amplia distribución en Australia, Nueva Zelanda, Sud América y la porción subantártica que comprende la zona helada austral. El investigador Bayly en 1992 en un trabajo sobre la fusión del género *boeckella* y *pseudoboeckella*, aún sin definirse, y en una revisión de sus especies procedentes de América del Sur e islas subantárticas reportó tan solo la presencia de *boeckella poopoensis* en el lago poopó descrita por primera vez por Kiefer en 1928 (Ramos, Dávila & Pinto, 2006).

Los primeros estudios sobre el zooplancton del lago Titicaca fueron realizados por investigadores que trabajaron con el material colectado por misiones itinerantes. Así, en 1939, De Beauchamp determina seis especies de rotíferos y en 1995, Harding realiza un estudio sobre los cladóceros y copépodos con las colecciones efectuadas por la expedición Percy Salden en 1937 (Pinto, 1991).

Posteriormente, Kiefer en 1957 efectúa una revisión más detallada de los copépodos con la descripción de nuevas subespecies y en 1967, Ueno realiza un trabajo general sobre el zooplancton del Huiñaimarca, parte boliviana, tomando en cuenta copépodos, cladóceros y rotíferos. Se indican las características taxonómicas y la repartición geográfica de algunas especies. Richerson y su equipo en 1977, en un estudio sobre el Lago Mayor, consideran por primera vez el aspecto biomasa de los doblamientos tanto para el fitoplancton como para el zooplancton y determinan las variaciones cuantitativas estacionales de algunas especies. Pawlety en 1982 y 1983 analiza la

repartición del zooplancton en el Lago Mayor respecto a los nutrientes presentes. Moreno en 1983 efectúa un estudio cuantitativo del plancton en la zona pelágica del Lago Mayor y determina la abundancia de los microcrustáceos y rotíferos en un transecto frente a las bahía de Puno.

Haney y Trout en 1985 realizan experimentos en el hábitat natural y en laboratorio sobre los hábitos alimenticios de copépodos y cladóceros con partículas seleccionadas del Sestón y de *Chlorella* inoculadas con carbono 14. En 1987 y 1988, Repelin determina la abundancia espacio temporal del zooplancton en la parte boliviana del lago relativa a copépodos, cladóceros y larvas nauplios; se realiza mapas de repartición del zooplancton tanto para el Lago Mayor como para el Lago Menor y analiza, también en el Huiñaimarca, las migraciones de algunos grupos (Pinto, 1991).



3. REDES NEURONALES ARTIFICIALES

Resumen

En este capítulo se muestra una introducción y la utilidad de las redes neuronales artificiales basadas en el funcionamiento biológico. Incluye los principios y la metodología del desarrollo de redes neuronales artificiales. Además se presenta el uso del algoritmo de retropropagación que permite el proceso en paralelo, capaz de ignorar el ruido y aprender, de las tramas vistas a priori.

3.1. INTRODUCCIÓN

El interés por las redes neuronales se debe a que fueron diseñadas para que su capacitación se realice mediante un algoritmo de aprendizaje inductivo²⁷. Una vez inicializada la red, ésta puede ser modificada para mejorar su eficiencia en los pares de entrada/salida. En la medida que sea posible dar eficiencia y generalidad a los algoritmos de aprendizaje, aumentará el valor de las redes neuronales en cuanto a modelos psicológicos y los convierte en herramientas útiles para la creación de una gran diversidad de aplicaciones de alto rendimiento (Russell & Norvig, 1996).

Las redes neuronales artificiales realizan el paradigma subsimbólico de representación y procesamiento de información. El área de la ciencia que lidia con métodos y sistemas para el procesamiento de la información usando redes neuronales es llamado neurocomputación (Kasabov, 1998).

Dichas redes están interconectadas masivamente en paralelo con elementos simples (usualmente adaptativos) y con organización jerárquica, las cuales intentan interactuar con los objetos del mundo real del mismo modo que lo hace el sistema nervioso biológico. El interés por las redes neuronales se debe a que fueron diseñadas para que su capacitación se realice mediante un algoritmo de aprendizaje inductivo. Una vez inicializada la red, ésta puede ser modificada para mejorar su eficiencia en los pares de entrada/salida. En la medida que sea posible dar eficiencia y generalidad a los algoritmos de aprendizaje, aumentará el valor de las redes neuronales en cuanto a modelos psicológicos y los convierte en herramientas útiles para la creación de una gran diversidad de aplicaciones de alto rendimiento (Hilera & Martínez, 1995).

3.2. REPRESENTACIÓN NEURONAL

El problema principal con respecto a la representación mental, es determinar la naturaleza aproximada de la relación de la representación, es decir, para especificar la relación entre las propiedades pertinentes de las cosas 'dentro' y 'fuera' de la cabeza. El acercamiento tradicional para resolver este problema es considerar los datos (ampliamente construidos) disponibles en: la metafísica, la introspección, la psicología y más recientemente la neurociencia, para deducir: 1) la relación de la representación; y 2) las maneras de determinar qué cosas son las representaciones y qué cosas se representan.

²⁷ Contrariamente a la opinión creada por los medios masivos, las redes neuronales distan mucho de ser los únicos sistemas de inteligencia artificial capaces de aprendizaje.

Los códigos, en ingeniería son definidos de una decodificación complementaria y procesos decodificados entre dos alfabetos. El código Morse, por ejemplo es definido por la relación de uno a uno entre letras del alfabeto romano y el alfabeto compuesto de rayas y puntos.

El enfoque de la neurociencia está tratando de entender como los sistemas nerviosos codifican más que las propiedades físicas básicas. Eventualmente, se necesita ser hábil para explicar como las propiedades del principio “comestible”, o el principio de un “objeto” es codificado por neuronas.

Esta estructura es suficientemente flexible para ayudar con este problema, pero por el tiempo se comienza a enfocar la atención en la caracterización de las propiedades físicas más básicas, donde se cree que el éxito puede ser convincentemente demostrado. Esto es como una “representación neuronal”, en neurociencia puede ser definida analógicamente para ver como los “códigos” son definidos en comunicaciones de ingeniería.

Al principio de las exploraciones de sistemas neuronales. Hay dos fuentes de tales arbitrariedades. (1) Primero, desde que el conocimiento es representado depende en parte de como es subsecuencialmente usado, parece ser como el ser humano esta listo para conocer el orden en el que funcionan los sistemas y saber que esta representando. El sistema es precisamente el que se trata de figurar fuera cuando se habla acerca de representación.

Este problema no es un obstáculo, una vez explicado los problemas mas difíciles, estos son resueltos haciendo especulaciones acerca de cómo funcionan las cosas y entonces se realizan exámenes de las especulaciones (idealización del método científico). Pese a lo representado, el problema solo será resuelto una vez que se tenga medianamente entendimiento comprensivo de lo que actualmente esta representando el cerebro, esto no debería ser tomado como una dificultad insuperable, o un círculo vicioso. Especialmente, esto no significa que el proceso de la hipótesis este erróneo, solo lo que podría ser. En efecto lo que es “realmente” representado de las funciones cerebrales es: una representación más o menos completa, coherente, consistente.

Una teoría al menos de algunas décadas pasadas. Pero esto no significa que sea inútil para hacer ahora aseveraciones representacionales; de hecho, hacer tales representaciones es un paso esencial hacia tal teoría.

(2) La segunda fuente de la arbitrariedad aparente descende del hecho de que la información es codificada por una población neuronal que puede ser decodificada de varias maneras. Para ver porque, se considera que una población neuronal se codifica rápidamente, se puede decodificar la información llevada por esta población que da una salida estimada. Sin embargo, también se decodifica la misma información para dar un estimado de una “función de velocidad visual”.

Esto se debe a que los “pesos” son esencialmente la información, sin embargo se ve cuando la actividad de la población es decodificada; diferentes pesos resultan en una decodificación diferente de funciones. Desde que la representación esta definida en términos de codificaciones y decodificaciones, necesita un camino para obtener cuales de estas posibles decodificaciones son relevantes para definir la representación de la población original. Se resuelve este cometido especificando la representación de la población que es determinada por la decodificación de los resultados en la cantidad que todas las otras decodificaciones son funciones.

Esto es “representación decodificada”. Por ejemplo, la población podría ser dicha como representación de rendimiento porque rendimiento y el cuadrado de rendimiento son decodificados (Eliasmith & Anderson, 2003).

3.2.1. Neurona Simple

Tres niveles pueden ser distinguidos en el cerebro humano desde el punto de vista del procesamiento de información: (1) el nivel estructural las neuronas, regiones de neuronas, y las conexiones entre ellas; (2) el nivel físico; la forma de proceso de información del cerebro como las reacciones químicas y físicas, y la transmisión de sustancias; y (3) el nivel cognitivo la forma humana de pensar. Tres puntos son serán brevemente discutidos: (a) la estructura y organización del cerebro, (b) el cerebro como un sistema de comunicación que es masivamente paralelo y robusto, y (c) las funciones principales de procesamiento de información (Kasabov, 1998).

Las neuronas comparten muchas características con las otras células del cuerpo, pero ellas tienen capacidades de recepción, procesamiento y transmisión de señales electroquímicas únicas, sobre los caminos neuronales que hacen al cerebro un sistema de comunicación. Figura 3.1 muestra la estructura de una neurona biológica típica (Kasabov, 1998).




Figura 3.1: Estructura de una neurona biológica
Fuente: (Kasabov, 1998)

Las características del cerebro son: aprendizaje, memoria, generalización, almacenamiento asociativo y comportamiento caótico. El cerebro humano contiene cerca de 10^{11} neuronas y aproximadamente 10^{15} interconexiones sobre los caminos de transmisión. Cada uno de esos caminos podrían ser un metro de largo o más (Kasabov, 1998).

Para adoptar una perspectiva de ingeniería relativa a la función neuronal, se puede empezar por preguntar: ¿Que tipo de dispositivos físicos son las neuronas? Afortunadamente hay un consenso en la respuesta de esta pregunta; las neuronas son dispositivos electroquímicos. Aún el comportamiento de simples neuronas puede ser caracterizado en términos de sus propiedades eléctricas. De hecho, el detalle, la cantidad y modelos altamente precisos del comportamiento de

una simple célula han sido estudiados alrededor de 50 años y continúan siendo perfeccionados (Eliasmith & Anderson, 2003).

Las neuronas están compuestas de un cuerpo celular, también llamado soma, y una o varias ramas. Según la definición tradicional, las ramas conducen información dentro una célula (estímulo) son llamadas dendritas y las ramas que conducen información fuera de la célula (reacción) es llamada axón. La activación de una neurona, llamada una acción potencial, es transmitida a otras neuronas a través de su axón a la primera instancia. Una señal (ajuste) emitida desde una neurona es caracterizada por la frecuencia, duración y amplitud.

La interacción entre neuronas toma lugar en puntos de contacto estrictamente determinados llamados sinapsis. En la región de la sinapsis, las neuronas casi se “tocan” una a otra; aquí siempre hay una diminuta grieta entre ellas. En una sinapsis, dos partes pueden ser distinguidas: (1) una membrana presináptica, perteneciendo a la neurona transmisora, y (2) una membrana postsináptica, que pertenece a la neurona receptora. Un impulso emitido desde la neurona transmisora y alimenta a la parte presináptica de una sinapsis que induce el descargo de un transmisor.

El transmisor lleva una sustancia conocida como un mediador. Como los pasos del transmisor por la hendidura, toma el mediador a la parte de la postsináptica. Allí, bajo su influencia, la permeabilidad de la membrana de la neurona receptora cambia proporcionalmente a la suma algebraica de los potenciales recibidos en todas las partes de la postsinapsis de esta neurona. Si el resultado supera un valor del umbral establecido de antemano, la neurona en su giro asume la función de transmitir un potencial de acción (Kasabov, 1998).

La mayoría de los cuerpos de las neuronas pueden ser entendidos como dispositivos físicos que convierten un voltaje de “entrada” que cambia en sus dendritas a un voltaje de “salida” que se ajusta en el entrenamiento viajando por su axón. Este entrenamiento de ajuste es el resultado de altos procesos no lineales en el soma de la neurona que se apoya en la interacción de diferentes tipos de voltaje de entrada con los canales de ión en la membrana celular. Este entrenamiento de ajuste causa más cambios eléctricos (postsinapsis) en las dendritas que recibe la neurona. Las mismas dendritas tienen propiedades eléctricas de activación similares a las del soma, debido al soma de las dendritas (Eliasmith & Anderson, 2003).

El mismo voltaje del soma esta determinado por el actual flujo dentro del mismo, desde las dendritas, como la activación, la resistencia pasiva de la membrana y la capacitancia pasiva de la membrana. Típicamente, el tiempo constante de la membrana pasiva en el soma (determinado por la resistencia pasiva y la capacitancia) esta en orden de alrededor de 10 milisegundos.

Este tiempo constante efectivamente esta caracterizado a tiempo-escala de la “memoria” del soma con respecto a lo largo de las señales. Así, el proceso de generación de señales solo “recuerda”(o es sensitivo) las entradas dendríticas que ocurrieron a lo largo de la mas reciente talvez hace 200 milisegundos atrás, pero generalmente en las decenas de milisegundos. Entonces, son considerados como dispositivos eléctricos, neuronas que tienen procesos de entradas altamente no lineales (a las dendritas) procesos de salida altamente no lineales (en el soma, resultando del voltaje en el entrenamiento de ajuste) y una memoria de señal medianamente corta en ambos: dendritas y soma (Kasabov, 1998).

3.2.2. Red neuronal

El cerebro consiste en tipos diferentes de neuronas. Ellas difieren en la forma (piramidal, granular, curva, etc.) y en sus funciones especializadas. Hay una correlación entre la función de una célula y su forma; por ejemplo, las células piramidales son excitadoras y las células curvas son inhibidoras. Por lo que se refiere a la variedad, se encuentran encima de 50 tipos de neuronas funcionalmente diferentes en el cerebelo (una de las partes mayores del cerebro).

Este hecho puede influenciar la creación de modelos computacionales neuronales heterogéneos que consiste de tipos diferentes de neuronas artificiales especializadas. El cerebro humano es un sistema de comunicación complicado. Este sistema transmite los mensajes como impulsos eléctricos que siempre parecen los mismos, repitiéndose en una sucesión monótona. Un impulso muy pequeño del nervio lleva la información; por consiguiente, procesar la información compleja sólo es posible por la interacción de grupos de muchas neuronas y fibras del nervio que son enormes en el número y tamaño.

La longitud total de todas las bifurcaciones neuronales dentro del cuerpo humano son aproximadamente 1014 metros. La presencia de tal número elevado de conexiones determina un nivel alto de paralelismo masivo que es específico a los mecanismos del cerebro. De hecho, mientras cada neurona reacciona relativamente despacio a los estímulos externos (la reacción de una neurona toma aproximadamente 200 milisegundos), el cerebro humano es en conjunto capaz de resolver los problemas complejos en una parte de tiempo comparativamente corto, de un segundo o varios segundos.

La habilidad del cerebro de analizar los problemas complejos y reaccionar adecuadamente a las situaciones poco familiares es debida a su facultad heurística de tomar las decisiones en base al conocimiento previamente guardado y su habilidad de adaptar a las nuevas situaciones. El cerebro humano tiene la habilidad para aprender y generalizar. Guarda la información que se acumula como resultado del aprendizaje en la sinapsis en la forma de sustancias químicas concentradas (Kasabov, 1998).

Hay dos importantes resultados. Primero, es extremadamente favorable que se pueda extraer información que fue no linealmente codificada usando un decodificador lineal porque permite muchas de las herramientas de señales lineales y teoría de sistemas. Segundo, a menudo no se da suficientemente énfasis a las propiedades de heterogeneidad de los sistemas neuronales transformados. Según esta perspectiva la heterogeneidad de las poblaciones neuronales pueden ser explicadas desde una perspectiva funcional; de hecho, la heterogeneidad se vuelve indispensable para una buena representación. Esto tiene consecuencias significativas para ambos, experimentadores y teorificadores. Especialmente, este resultado demuestra que es mucho mas apropiado para experimentadores.

La perceptibilidad de la representación neuronal a propiedades de nivel poblacional como heterogeneidad y el número de neuronas, sugiere que es más provechoso pensar en una representación neuronal en términos de poblaciones que en términos de simples neuronas. Así, se argumenta que en la unidad fundamental del procesamiento de señales en el sistema nervioso esta la población neuronal mas simple (un par de neuronas).

La flexibilidad es provechosa porque el direccionamiento es una importante necesidad en la neurociencia, según Marder en 1997: "Idealmente, se desea que se pueda mover con facilidad entre

niveles de modelos y para entender como reducir sistemáticamente modelos mas complejos dentro de formas simples que retienen estas propiedades esenciales”. El análisis de representación direccionada esta basada en la necesidad de soportar al mismo tiempo varios niveles de representación; desde representaciones de poblaciones altamente abstractas a representaciones detalladas por modelos de transición de una célula. Cuando se formalicen esos niveles de representación, se discute como definir una representación jerárquica que abarca los niveles de estructura biológica desde neuronas simples a través de redes y mapas de áreas del cerebro (Eliasmith & Anderson, 2003).

3.2.3. Neuronas artificiales

Según Kasabov (1998), el primer modelo matemático de una neurona fue propuesto por McCulloch y Pitts en 1943. El mismo consistía en un dispositivo binario que usa entradas binarias, salidas binarias y un umbral de activación fijo. En general, el modelo de una neurona artificial es basado en los siguientes parámetros que describen una neurona (Figura 3.2):




Figura 3.2: Modelo de una neurona artificial

Fuente: (Kasabov, 1998)

1. Conexiones de entrada (o entradas): x_1, x_2, \dots, x_n . Existen pesos limitados a las conexiones de la entrada: w_1, w_2, \dots, w_n ; una entrada a la neurona, llamada bias, tiene un valor constante de 1 y normalmente se representa como una entrada separada, como x_0 , o simplemente una entrada, sujeta a un valor constante.
2. La función de entrada f , calcula la señal de la entrada neta agregada a la neurona $u = f(x, w)$, donde x y w son la entrada y vectores de peso correspondientemente ; f normalmente es la función de la suma: u
3. Una función de activación s (señal) calcula el nivel de activación de la neurona $a = s(u)$.

Las redes neuronales artificiales son modelos que intentan reproducir el comportamiento del cerebro. Realiza una simplificación averiguando cuáles son los elementos relevantes del sistema, esto se debe a que la cantidad de información de que se dispone es excesiva o bien es redundante. Una elección adecuada de sus características, más una estructura conveniente, es el procedimiento convencional utilizado para construir redes capaces de realizar una determinada tarea. A continuación se describe los componentes de una red neuronal artificial (Hilera & Martínez, 1995):

1. **Unidades de proceso.** Si se tiene N unidades (neuronas), se ordena arbitrariamente y se designa la j -ésima unidad como U_j su trabajo es único, y consiste en recibir las entradas de las células vecinas y calcular un valor de salida, el cual es enviado a todas las células restantes. En cualquier sistema que se esté modelando, es útil caracterizar tres tipos de unidades: entrada, salida y ocultas. Las unidades de entrada reciben señales desde el entorno;

estas entradas (que son a la vez entradas de la red) pueden ser señales provenientes de sensores o de otros sectores del sistema. Las unidades de salida envían la señal fuera del sistema (salidas de la red); estas señales controlan directamente potencias u otros sistemas. Las unidades ocultas son aquellas cuyas entradas y salidas se encuentran dentro del sistema; es decir, no tienen contacto con el exterior.

2. **Función de salida o de transferencia.** Asociada con cada unidad existe una función de salida, que transforma el estado actual de activación en una señal de salida. Existen cuatro funciones de transferencia típicas que determinan distintos tipos de neuronas: función escalón, función lineal y mixta, función sigmoideal y función gaussiana.
3. **Conexiones entre neuronas.** Las conexiones que unen a las neuronas que forman una red neuronal tienen asociado un peso, que es el que hace que la red adquiera conocimiento. Se considera que el efecto de cada señal es aditivo, de tal forma que la entrada neta que recibe una neurona es la suma del producto de cada señal individual por el valor de la sinapsis que conecta ambas neuronas y es lo que se conoce como red de propagación. Suele utilizarse una matriz W con todos los pesos, Si w_{ji} es positivo indica que la relación entre las neuronas es excitadora, es decir, siempre que la neurona i esté activada, la neurona j recibirá una señal que tenderá a activarla. Si w_{ji} es negativo, la sinapsis será inhibidora. En este caso si i está activada, enviará una señal que desactivará a j . Finalmente si w_{ji} es 0 se supone que no hay conexión entre ambas.
4. **Función de activación.** Se requiere una regla que combine las entradas con el estado actual de la neurona para producir un nuevo estado de activación. Esta función F produce un nuevo estado de activación en una neurona a partir del estado que existía y la combinación de las entradas con los pesos de las conexiones. En la figura 3.3 se observan tres tipos de funciones de activación, función umbral escalón, umbral lineal y función sigmoideal.
5. **Regla de aprendizaje.** Biológicamente, se suele aceptar que la información memorizada en el cerebro está más relacionada con los valores sinápticos de las conexiones entre las neuronas que con ellas mismas; es decir, el conocimiento se encuentra en las sinapsis. En el caso de las redes neuronales artificiales, se considera que el conocimiento se encuentra representado en los pesos de las conexiones entre neuronas. Todo proceso de aprendizaje implica cierto número de cambios en estas conexiones. En realidad, se dice que aprende modificando los valores de los pesos de la red.

3.2.4. Transformación neuronal

La transformación como representación, puede ser caracterizada usando una decodificación lineal. Por lo anterior la codificación representacional puede ser llamada decodificación transformacional. El contraste entre esos dos tipos de decodificadores se basa en el hecho que, cuando se ejecuta una transformación sobre una información codificada, se intenta extraer *otra* información que la población ha tomado para representar.

La codificación transformacional, entonces, no es “pura” decodificación de la información codificada. Concretar transformaciones de esta manera permite usar una leve variación del análisis representacional para determinar que transformaciones de una población neuronal pueden soportar las transformaciones. Esto permite determinar como una población neuronal puede soportar transformaciones definidas por una clase particular de función. Esto puede ser muy importante para

contrastar la hipótesis acerca del rol funcional de poblaciones neuronales particulares que son observadas en sistemas neurobiológicos. Esta es una buena razón para pensar que las poblaciones con esas propiedades están involucradas en el cómputo de transformaciones certeras más que otras. En otras palabras, esta aproximación habilita una buena caracterización cuantitativa de la función potencial del conjunto de neuronas.

Definir transformaciones de esta forma permite encontrar analíticamente pesos de conexiones en una red biológica. Entonces en vez de tener que entrenar una red conectada totalmente usando una regla de aprendizaje, se puede definir las representaciones que podrían estar en el sistema y las transformaciones de esas representaciones experimentadas y entonces directamente encontrar los pesos para implementar esas transformaciones. Esto es beneficioso y permite probar la hipótesis acerca de la función de un sistema neuronal particular, sin tener que preocuparse acerca de entrenar el sistema para ejecutar alguna función. Hay un significado práctico en términos de ahorro computacional, en donde no se tiene que simular un régimen de largo entrenamiento para modelos complejos. Notablemente esto no significa que se aprenda de manera contraria a la aproximación, esto simplemente significa que no se necesita confiar en un entrenamiento para tener algo sustancial (Eliasmith & Anderson, 2003).

Según el tipo de valores que cada uno de los parámetros anteriores, puede tomar tipos diferentes de neuronas que han sido usadas hasta ahora. Los valores de entrada y de salida de una neurona pueden ser binarios, $\{0, 1\}$; bivalente, $\{-1, 1\}$; continuo, $[0, 1]$; o números discretos en un intervalo definido (Kasabov, 1998).




Figura 3.3: Funciones de activación
Fuente: (Kasabov, 1998)

Las funciones de activación más usadas se muestran en la figura 3.3: (a) Umbral Escalón; (b) Umbral lineal: si la entrada está sobre el umbral, la salida se satura (al valor de 1); hay diferentes variantes de esta función dependiendo del rango del valor de la neurona de salida mostrado en (b-1) y (b-2); (c) función sigmoideal: función logística (c-1); función logística bipolar (c-2); (c-3) función gaussiana. Estas son (Kasabov, 1998):

1. **Función de umbral escalón.** Si el valor de la entrada neto u a la neurona esta sobre cierto umbral, la neurona se activa (el valor de activación de 1); sino se queda inactivo (el valor de activación de 0) (figura 3.3 (a)).
2. **Función de umbral lineal.** El valor de activación aumenta linealmente con el aumento de la señal neta de entrada u , pero después de un cierto umbral, la salida se satura (a un valor de 1); hay variantes diferentes de esta función que depende del rango de los valores de salida neuronal (figura 3.3 (b-1) y (b-2)).
3. **Función sigmoideal.** Esta es cualquier función de transformación no lineal de forma S $g(u)$ es decir caracterizada por lo siguiente:
 - a. Limite, es decir, sus valores se restringen entre dos límites, por ejemplo, $[0, 1]$, $[-1, 1]$.
 - b. Monotómicamente incrementado, es decir, el valor $g(u)$ nunca decrementa cuando u incrementa.
 - c. Continuo y uniforme, por consiguiente diferenciable por todas partes en su dominio. Diferentes tipos de funciones sigmoideas son usadas en la práctica. La mayoría de ellas son funciones logísticas (figura 3.3 [c-1]). En una forma más general, la función logística puede escribirse como: $a = 1/(1 + e^{-c \cdot u})$, donde c es una constante.

La razón por qué la función logística se ha usado como una función neuronal de activación es que muchos algoritmos al realizar el aprendizaje en las redes neuronales usan el derivado de la función de activación, y la función logística tiene un derivado simple, $g' / u = a(1 - a)$. Las alternativas a la función logística, como funciones S son las logísticas bipolares: $h(u) = (1 - e^{-u})/(1 + e^{-u}) = 2 g(u) - 1$; esta función tiene un rango de $[-1, 1]$ (figura 4.3 (c-2)) y la tangente hiperbólica: $\tanh(u) = (e^u - e^{-u})/(e^u + e^{-u})$.

4. **Funcion Gaussiana** (figura 3.3 (c-3)). Una señal de salida desde la neurona puede ser representada por un simple potencial estático, o por un pulso cualquiera que ocurre (codificado como 1) o no ocurre (codificado como 0) (Figura 3.4).

Además sobre los tipos de las neuronas descritos, se han desarrollado muchos otros tipos y se han usado: la neurona difusa, neurona oscilatoria, neurona caótica, y neurona ondulatoria. Estas han demostrado ser muy útiles para construir las redes neuronales artificiales para el diseño de aplicaciones.




Figura 3.4: Pulsos y potencial codificado de una señal de salida de una neurona.
Fuente: (Kasabov, 1998)

3.3. PRINCIPIOS DE LA INGENIERÍA NEURONAL

Los tres principios según Eliasmith & Anderson (2003):

1. Las representaciones neuronales son definidas por combinaciones de códigos no lineales (Ejemplo una neurona afinando curvas) y el peso lineal decodificado.
2. Las transformaciones de representaciones neuronales son funciones de variables que están representadas por poblaciones neuronales. Las transformaciones se encuentran determinadas usando alternadamente un peso lineal decodificado.
3. Las dinámicas neuronales son caracterizadas considerando representaciones neuronales como la teoría de control del estado de las variables. Las dinámicas de los sistemas neurobiológicos pueden ser analizadas usando una teoría de control.

Se toma estos tres principios que son una excelente guía para la construcción de sistemas biológicos, simulaciones de sistemas neurobiológicos a larga escala. Es prematuro declarar estos principios más cuantitativamente. En adición para estos tres principios hay uno que guía el análisis de sistemas neurobiológicos:

4. Los sistemas neuronales están sujetos a una cantidad significativa de ruido. Por consiguiente, cualquier análisis de estos sistemas debe justificar los efectos del ruido. Este punto no se considera principal por que, existen pasos para explicar el funcionamiento de los sistemas neurobiológicos, esta es una guía de cómo explicar el análisis para dichos sistemas. No obstante es esencial para articular los principios en detalle.

3.3.1. Principio uno

El primer principio enfatiza la importancia de identificar la codificación y la decodificación cuando se definen las representaciones neuronales. Este principio aclara la suposición central, a pesar de una codificación no lineal, una decodificación lineal es válida, una función de respuesta no lineal como las neuronas típicas, no esta muy relacionado o por lo menos no con la señal resultante que pueda ser linealmente decodificada. Esto es, la naturaleza de la función de entrada y salida de un dispositivo que es independiente del decodificador que necesita estimar sus entradas.

Esto significa que la codificación no lineal podría necesitar una decodificación lineal o no lineal, y viceversa. Esto es por que la decodificación depende de la probabilidad condicional de entradas que dan las salidas y de las estadísticas del ruido. Específicamente la información adicional obtenida con decodificación no lineal es generalmente menos que el 5%. Por supuesto, la decodificación no lineal puede ser tan bien o mejor que la decodificación lineal en la extracción de la información, pero el precio pagado en realidades biológicas es generalmente alta.

Se asume que la decodificación lineal en el nivel neurona (o sub neurona) puede bien ser consistente con una decodificación no lineal en el nivel red (o neurona) entonces especialmente en combinación con el principio 2, la decodificación lineal es un buen candidato para describir la decodificación neuronal en general.

Es importante enfatizar que analizando neuronas como señales decodificadas usando filtros lineales o no lineales (óptimos) no significa que las neuronas son supuestas para explicar el uso óptimo de filtros. De hecho no hay contraparte observable directamente para esos decodificadores óptimos.

Esto significa que si se cambia un peso conector, cambia la transformación siendo ejecutada y la curva de afinamiento de la neurona receptora. Es bueno saber sobre el trabajo en una red neuronal artificial y la neurociencia computacional, esto es exactamente lo que debería pasar. En esencia, la diferencia entre codificación y decodificación no es una que los sistemas neurobiológicos necesiten para respetar el orden para la ejecución de sus funciones, pero es extremadamente útil en el entrenamiento para entender los sistemas y como funcionan, de hecho, para lograr la ejecución de esas funciones (Eliasmith & Anderson, 2003).

3.3.2. Principio dos

En los comentarios precedentes acerca de decodificadores representacionales aplicados igualmente a los decodificadores transformacionales, no se enfatizó los tipos de transformaciones que pueden ser soportados con una decodificación lineal. Esto tiene a menudo que estar siendo argumentado para transformaciones no lineales que están por el tipo más común de transformaciones encontradas en los sistemas neurobiológicos.

Esto no debería ser sorprendente para los ingenieros, como para la mayor parte de control de problemas del mundo real requieren complejidad, análisis de control no lineal; un buen ejemplo contemporáneo es un sistema manipulador remoto sobre una estación espacial internacional. Es esencial estar capacitados para dar explicaciones sobre “no lineal” también como para las transformaciones lineales (Eliasmith & Anderson, 2003).

3.3.3. Principio tres

Hay características de teoría de control que son extremadamente útiles para el modelado de sistemas neurobiológicos. Primero, la forma general de control de sistemas, capturados por ecuaciones estado-espacio, pueden ser usadas para relatar las dinámicas de subsistemas neurobiológicos. Segundo, la comunidad de ingeniería es muy familiar con las aproximaciones estado-espacio para describir las propiedades dinámicas de sistemas físicos y así contiene muchas herramientas analíticas descritas para caracterizar tales sistemas. Tercero, la teoría de control moderno puede ser usada para describir las dinámicas de variables “externas”, variables “internas” o ambas. Esto demuestra como un formalismo puede ser usado para extenderse a lo largo de descripciones internas y externas de comportamiento.

La teoría de control no lineal contemporánea, la cual puede ser mas valiosa con el paso del tiempo, depende críticamente del entendimiento actual de los sistemas lineales.

De esa manera, mostrando como la teoría de control lineal funciona para sistemas neurobiológicos, muestra también como teoría de control no lineal funciona correctamente para sistemas neurobiológicos (Eliasmith & Anderson, 2003).

3.4. METODOLOGÍA

A continuación se presenta una metodología en 3 estados: descripción de sistema, especificación de diseño e implementación.

3.4.1. Descripción del sistema

La meta principal de la descripción del sistema consiste en el relevamiento relacionado con las características centrales del sistema neurobiológico a desarrollar, los problemas que resuelven las redes neuronales suelen estar centrados con preferencia en tres áreas diferenciadas: (1) tareas de clasificación y categorización, (2) reconocimiento de patrones y (3) labores de predicción. Los datos neuronales disponibles y cualquier conocimiento funcional, relativo al problema a resolver, se utiliza para describir la arquitectura, la funcionalidad, y la representación del sistema neuronal. Esta descripción debe incluir al menos: (1) la conexión interna básica entre los subsistemas, (2) las funciones de respuesta de las neuronas, (3) las curvas de afinado de la neurona, (4) las relaciones funcionales de los subsistemas y (5) el comportamiento completo del sistema.

Con la información disponible, se podría tener una base para construir un modelo. Como resultado, muchos de esos detalles probablemente serán hipótesis. El punto es hacer explícitas las suposiciones que informan el modelo.

Entonces, cualquier diferencia entre la función del modelo y la función del sistema modelado puede ser seguida luego de la ejecución del programa, línea por línea a esas suposiciones.

Las dos últimas descripciones funcionales (4 y 5) necesitan ser expresadas en términos matemáticos. En particular, las representaciones neuronales relevantes necesitan ser especificadas de tal manera que puedan ser usadas para escribir transformaciones explícitas que ejecutan las funciones especificadas. El objetivo es traducir la descripción funcional provista en términos neurobiológicos dentro una descripción en términos matemáticos.

Por ejemplo, se puede describir un subsistema neuronal particular tanto actuando como trabajando en la memoria para locaciones espaciales. Para proveer una descripción matemática, se debe identificar una variable representada, unidades (grados de la línea media) y una descripción de las dinámicas que capturan la noción de memoria.

En este caso, hay una correspondencia natural entre tiempos derivados igualando a cero y la memoria, la cual se debe explotar. En la mayor parte de casos, la interpretación esta mucho mas involucrada.

Si este subsistema es parte de un sistema neuronal mas grande del que se esta interesado en simular, entonces un procedimiento similar debe ser llevado a cabo para cada subsistema. La teoría de control expresada como diagramas puede ser muy útil para ejecutar esta descomposición.

Esencialmente, este paso requiere una formulación rigurosa de hipótesis, la cual se puede tener respecto a la función del sistema en el que se esta interesado. Esta descripción matemática puede ser altamente abstracta. Pero eso es aceptable siempre que la descripción este completa. Esto no es necesario para hacer hipótesis acerca del funcionamiento de cada neurona individual o un grupo neuronal, siempre que se tenga una hipótesis acerca del comportamiento global. De hecho el marco

de trabajo tiene la intención de ser el medio de determinar el rol probable de las neuronas o del grupo de neuronas en niveles bajos.

Algunas diferencias entre los resultados de la simulación y propiedades neurobiológicas conocidas de esos niveles bajos (conectividad, aproximación de curvas, etc.) deberían ayudar a mejorar el nivel más alto de la hipótesis. Dando la formulación perfeccionada del nivel más alto, las propiedades neuronales previstas pueden ser examinadas otra vez, y así sucesivamente. De esta manera, esta metodología respalda un aproximado “bootstrapping”²⁸ para el entendimiento de sistemas neuronales (Eliasmith & Anderson, 2003).

En adición, al propósito principal de este paso están los siguientes puntos (Eliasmith & Anderson, 2003):

1. Identificar las restricciones neurobiológicas relevantes.
2. Identificar las variables del sistema representado.
3. Describir rigurosamente esas variables una a otra de tal manera que resulte el comportamiento observado.

3.4.2. Especificación del diseño

El propósito de la especificación del diseño consiste en delinear las limitaciones conocidas del mundo real para el sistema neuronal. Como resultado de su aplicación se debe ser explícito acerca de las condiciones operativas, tales como el ruido, a las cuales está sujeta el sistema. La meta principal de este paso consiste en especificar las restricciones de implementación en el modelo para cada variable representada identificada en el paso previo.

A pesar de que las especificaciones precisas puedan no parecer importantes, ellas pueden afectar significativamente al modelo final es decir al modelo generado. Esto tiene la intención de mostrar la significancia de las restricciones de implementación para la construcción de buenos modelos neurobiológicos. Por ejemplo, la diferencia por decibelios²⁹ entre la letra producida por un dispositivo audible y el ruido producido por el mismo dispositivo, debe ser extremadamente alta para una variable en particular, allí habrán muchas neuronas dedicadas para representar esa variable (o menos neuronas altamente precisas). Por el contrario, si se tiene buenas estimaciones del número de neuronas en un sistema en particular, se puede usar esa información para determinar posibles especificaciones de diseño. Adicionando al propósito principal de este paso, es para especificar las restricciones de implementación sobre el modelo para cada variable representada identificada en el paso previo (Eliasmith & Anderson, 2003).

3.4.3. Implementación

El tercer paso de la metodología involucra el diseño procedimental, la generación de código y la ejecución del modelo propiamente dicho. Dadas la descripción del sistema y las especificaciones de diseño, este paso combina los mismos para determinar las reglas apropiadas de decodificado, y por consiguiente los pesos sinápticos, necesarios para determinar el comportamiento deseado.

²⁸ Proceso de crear una curva de índice de sitio teórica usando una proyección de rendimiento como la base para el rendimiento de la del próximo crecimiento.

²⁹ Unidad de medida de la intensidad de sonido.

Porque la descripción del sistema original puede ser enmarcada en términos de representaciones neuronales de alto nivel, esto es a menudo posible para simular algunas partes del modelo en el nivel de esas representaciones (sin simular cada función de neurona individual) mientras se simula otras partes del modelo con ajuste realístico de neuronas. También, la cantidad de detalle en el modelo de neuronas individuales (modelo evaluado, modelo ajustado, o modelo conductual) pueden variar desde una parte del modelo a otra. El ahorro computacional de esas variaciones en detalle puede ser significativo para modelos de larga escala. En muchos casos, los modelos de larga escala no podrían ser simulados sobre un hardware disponible sin este tipo de control que sobrepasa la cantidad de detalle incorporado dentro de varias partes del modelo.

En general, el propósito de la implementación es ejecutar experimentos numéricos sobre el modelo. Estos experimentos pueden simplemente indicar el cambio de la entrada para la red, o ellos podrían involucrar cambios en las propiedades del sistema definidos en la especificación de diseño. La implementación representa de esta manera soportes ejecutando un análisis en profundidad del comportamiento del modelo (análisis de estabilidad, sensibilidad del ruido, etc.).

Los resultados de tales experimentos y análisis pueden ser usados para revisiones informativas a cualquiera de los dos primeros pasos. Al final, los resultados de tales experimentos numéricos a menudo sugieren experimentos neurobiológicos para perseguir en el sistema siendo modelado. En adición, el propósito principal del paso final de la metodología es aplicar los principios de la ingeniería neuronal previamente esquematizada para incrustar la descripción del sistema dentro de un modelo neuronal, analizar y experimentar con el resultado de la simulación (Eliasmith & Anderson, 2003).

3.5. RED DE RETROPROPAGACIÓN³⁰

Son muchas las posibles aplicaciones de las computadoras que resultan difíciles de realizar porque hay muchos problemas cuya resolución no es adecuada mediante procesos secuenciales. Las aplicaciones que deben realizar complejas traducciones de datos, y sin embargo no poseen una función de correspondencia predefinida que describa el proceso de traducción, o aquellas que deben proporcionar una “mejor aproximación” como salida cuando se les presentan unos datos de entrada con ruido son dos ejemplos de problemas de este tipo.

La red que se ilustra de forma general en la figura 3.5, esta diseñada para que funcione como red multicapa, con propagación hacia delante, empleando el modo supervisado de aprendizaje (Freeman & Skapura, 1993).

³⁰ Retropropagación del inglés Back Propagation Network.




Figura 3.5: Arquitectura general de una red de retropropagación

Fuente: (Freeman & Skapura, 1993)

Los problemas tales como la conversión de una imagen con ruido en un código ASCII³¹ son difíciles de resolver, debido a la incompatibilidad básica existente entre la máquina y el problema. La mayoría de los sistemas actuales de computadoras se han diseñado para llevar a cabo funciones matemáticas y lógicas con velocidades que resultan incomprensibles para ser el humano.

Incluso los microcomputadores relativamente poco sofisticados, que son comunes en la actualidad, pueden realizar cientos de miles de comparaciones numéricas o combinaciones por segundo.

De hecho, la búsqueda algorítmica no es lo que se necesita para reconocer tramas complejas en entornos ruidosos. La búsqueda algorítmica, incluso dentro de un espacio de entrada relativamente pequeño, puede llegar a consumir mucho tiempo. El problema es la naturaleza secuencial de la propia computadora; el ciclo “capturar-ejecutar” de la arquitectura de Von Neumann solo permite que la máquina realice una operación a la vez. En la mayoría de los casos, el tiempo que necesita la máquina para llevar a cabo cada instrucción es tan breve (típicamente, alrededor de una millonésima de segundo) que el tiempo total necesario incluso para un programa grande es insignificante para los usuarios humanos. Sin embargo, para aquellas aplicaciones que deban explorar un gran espacio de entradas, o que intentan correlacionar todas las permutaciones posibles de una trama compleja, el tiempo necesario (incluso para una máquina muy grande) puede volverse insostenible con gran rapidez.

Lo que se necesita es un nuevo sistema de procesamiento que sea capaz de examinar todos los píxeles de la imagen en paralelo. Idealmente, ese sistema no tendría que ser programado explícitamente; lo que haría es adaptarse a sí mismo para “aprender” la relación entre un conjunto de tramas dadas como ejemplo, y sería capaz de aplicar la misma relación a nuevas tramas de entrada.

Este sistema sería capaz de concentrarse en las características de una entrada arbitraria que se asemejase a otras tramas vistas previamente, tal como píxeles de una imagen ruidosa que “se

³¹ American Standard Code for Information Interchange, estándar ASCII, Código Estándar Americano para el Intercambio de Información. Código binario utilizado para representar letras, números, etc.

parecen” a un carácter conocido, y sería capaz de ignorar el ruido. Afortunadamente, existe un sistema así; este sistema recibe el nombre de red de retropropagación (Freeman & Skapura, 1993).

Una red de retropropagación puede ser entendida como un perceptrón multinivel, es decir una red con conexiones hacia delante, compuesta de varias capas de neuronas entre la entrada y la salida de la misma, esta red permite establecer regiones de decisión mucho más complejas que las de dos semiplanos, como lo hace el perceptrón de un solo nivel³² (Hilera & Martínez, 1995).

Los perceptrones multicapa fueron puestos en práctica solamente cuando los algoritmos de aprendizaje fueron desarrollados para ellos, uno de ellos comenzó con el llamado algoritmo de retropropagación. El nombre completo es el algoritmo del error de la retropropagación. Las neuronas tienen valores de entrada y salida continuos, función sumatoria de entradas y función de activación no lineal. La regla del gradiente descendiente se usa para encontrar pesos óptimos de conexiones w_{ij} , las cuales minimizan el error global E (Kasabov, 1998).

3.5.1. Funcionamiento

Para empezar, la red aprende un conjunto predefinido de pares de entradas y salidas dados como ejemplo, empleando un ciclo propagación y adaptación de dos fases. Una vez que se ha aplicado una trama de entrada como estímulo para la primera capa de la red, esta se va propagando a través de todas las capas superiores hasta genera una salida.

La señal de salida se compara entonces con la salida deseada, y se calcula una señal de error para cada unidad de salida. Las señales de error se transmiten entonces hacia atrás, partiendo de la capa de salida, hacia todos los nodos de la capa intermedia que contribuyan directamente a la salida. Sin embargo, las unidades de la capa intermedia solo reciben una fracción de la señal total de error, basándose aproximadamente en la contribución relativa que haya aportado la unidad a la salida original. Este proceso se repite, capa por capa, hasta que todos los nodos de la red hayan recibido una señal de error que describa su contribución relativa al error total. Basándose en la señal de error percibida, se actualizan los pesos de conexión de cada unidad, para hacer que la red converja hacia un estado que permita codificar todas las tramas de entrenamiento.

La importancia de este proceso consiste en que, a medida que se entrena la red, los nodos de las capas intermedias se organizan a si mismos de tal modo que los distintos nodos aprenden a reconocer distintas características del espacio total de entradas. Después del entrenamiento, cuando se les presente una trama arbitraria de entrada que contenga ruido o que este incompleta, las unidades de las capas ocultas de la red responderán con una salida activa si la nueva entrada contiene una trama que se asemeje a aquella característica que las unidades individuales hayan aprendido a reconocer durante su entrenamiento. Y a la inversa, las unidades de las capas ocultas tienen una tendencia a inhibir sus salidas si la trama no contiene la característica para reconocer la cual han sido entrenadas.

A medida que las señales se propagan a través de las diferentes capas de la red, la trama de actividad que esta presente en todas las capas superiores se puede ver como una trama con

³² El perceptrón fue el primer modelo de red neuronal artificial desarrollado por Rosenblatt en 1958. Despertó un enorme interés en los años 60, debido a su capacidad para aprender a reconocer patrones sencillos: un perceptrón, formado por varias neuronal lineales para recibir las entradas a la red y una neurona de salida, es capaz de decidir cuándo una entrada presentada a la red pertenece a una de las dos clases que es capaz de reconocer.

características que son reconocidas por las unidades de la capa subsiguiente. La trama de salida que se genera se puede ver como un mapa de características que ofrece una indicación de la presencia o ausencia de muchas combinaciones distintas de características dentro de la entrada. El resultado global de este comportamiento es que la BPN constituye un medio eficiente para permitir a un sistema de computadoras examinar tramas sutiles a partir de entradas parciales.

Hay varios investigadores que han demostrado que, durante el entrenamiento, las redes de retropropagación tienden a desarrollar relaciones internas entre nodos con el fin de organizar los datos de entrenamiento en clases de tramas. Esta tendencia se puede extrapolar, para llegar a la hipótesis consistente en que todas las unidades de capas ocultas de una red de retropropagación son asociadas de alguna manera a características específicas de la trama de entrada como consecuencia del entrenamiento. Lo que sea o no sea exactamente la asociación puede no resultar evidente para el observador humano. Lo importante es que la red ha encontrado una representación interna que le permite generar las salidas deseadas cuando se presentan entradas de entrenamiento. Esta misma representación interna se puede aplicar a entradas que no fueran utilizadas durante el entrenamiento. La red de retropropagación clasificara estas entradas que no había visto hasta el momento según las características que comparten con los ejemplos de entrenamiento (Freeman & Skapura, 1993).

3.5.2. Algoritmo

Se presentan todas las ecuaciones relevantes para la BPN por el orden en que serian utilizadas durante el entrenamiento para un par de vectores de entrenamiento (Freeman & Skapura, 1993).

1. Se aplica el vector de entrada $x_p = (x_{p1}, x_{p2}, \dots, x_{pN})^t$ a las unidades de entrada.
2. Se calculan los valores netos procedentes de las entradas para las unidades de la capa oculta:

$$neta_{pj}^h = \sum_{i=1}^N w_{ji}^h x_{pi} + \theta_j^h \quad (1)$$

3. Se calculan las salidas de la capa oculta:

$$i_{pj} = f_j^h(neta_{pj}^h) \quad (2)$$

4. Se pasa a la capa de salida. Se calculan los valores netos de las entradas para cada unidad

$$neta_{pk}^o = \sum_{j=1}^L w_{kj}^o i_{pj} + \theta_k^o \quad (3)$$

5. Se calculan las salidas:

$$o_{pk} = f_k^o(neta_{pk}^o) \quad (4)$$

6. Se calculan los términos de error para las unidades de salida:

$$\delta_{pk}^o = (y_{pk} - o_{pk}) f_k^{o'}(neta_{pk}^o) \quad (5)$$

7. Se calculan los términos de error para las unidades ocultas:

$$\delta_{pj}^h = f_j^{h'}(neta_{pj}^h) \sum_k \delta_{pk}^o w_{kj}^o \quad (6)$$

8. Los términos de error de las unidades ocultas se calculan antes que hayan sido actualizados los pesos de conexión con las unidades de la capa de salida.
9. Se actualizan los pesos de la capa de salida:

$$w_{kj}^o(t+1) = w_{kj}^o(t) + n\delta_{pk}^o i_{pj} \quad (7)$$

10. Se actualizan los pesos de la capa oculta:

$$w_{ji}^h(t+1) = w_{ji}^h(t) + n\delta_{pj}^h x_i \quad (8)$$

El orden de actualización de pesos de una capa individual no es importante. Se calcula el término de error.

$$E_p = \frac{1}{2} \sum_{k=1}^M \delta_{pk}^2 \quad (9)$$

Puesto que esta magnitud es la medida de lo bien que esta aprendiendo la red. Cuando el error resulta aceptablemente pequeño para todos los pares de vectores de entrenamiento, este se puede dar por concluido.

3.5.3. Datos de entrenamiento

En general, se pueden utilizar todos los datos que estén disponibles para entrenar la red, aunque quizá no sea necesario utilizarlos todos. Con cierta frecuencia, lo único que se necesario para entrenar con éxito una red es un pequeño subconjunto de los datos de entrenamiento de los que se dispone. Los datos restantes pueden emplearse para probar la red, con objeto de verificar que la red pueda llevar a cabo la asociación deseada al utilizar vectores de entrada que nunca haya durante el entrenamiento.

Algunas veces la adición de ruido a los vectores de entrada durante el entrenamiento ayuda a la red a converger, incluso en el caso de que no se espere ruido en las entradas.

Si la función de salida es una sigmoide, entonces será preciso aplicar una escala a los vectores de entrada. Como consecuencia de la forma de la función Sigmoidea, las salidas de la red nunca pueden alcanzar el cero ni el uno. Por tanto, hay que utilizar valores como 0.1 y 0.9 para representar los valores de entrada más pequeños y más grandes. También se puede desplazar la sigmoide de tal manera que, por ejemplo, los valores limitantes pasen a ser ± 0.4 . Además, se puede modificar la pendiente de la parte lineal de la curva sigmoide incluyendo una constante multiplicativa en la exponencial. Hay muchas posibilidades como estas que dependen fuertemente del problema que se este resolviendo (Freeman & Skapura, 1993).

El olvido catastrófico es un fenómeno que representa la habilidad de una red para olvidar lo que ha aprendido desde ejemplos previos, pero en su lugar otros ejemplos son representados. Esto se debe a un cambio en los pesos de acuerdo a lo nuevos ejemplos presentados, si los ejemplos pasados ya no son presentados para entrenamiento (o refrescar, readaptar). Con el propósito de evitar este fenómeno, un entrenamiento alternativo podría ser ejecutado, es decir, entrenamiento alternativo con nuevos datos y con viejos datos. El aprendizaje que se da ha entender en una red multicapa: En adición al conjunto de datos usados para el entrenamiento, se puede entrenar la red con algunos indicios existentes cerca de la función desconocida.

El conocimiento previo (indicio) puede ser introducido como un grupo de ejemplos que la red aprenda alternativamente desde el entrenamiento del grupo de datos hasta el error para ambos grupos de datos de entrenamiento es suficientemente pequeño.

Excepto por la generación de nuevos datos, que representan un indicio (una manera suave para acomodar el indicio), se puede usar uno explícito, una forma dura para introducir el indicio a la red para establecer una conexión extra entre los nodos. Por ejemplo, si se conoce que los atributos "carácter del postulado" es el atributo más importante para decidir en su aplicación, se introduce una conexión extra entre el nodo que representa el atributo "carácter" y el nodo de salida "decisión" (Kasabov, 1998).

3.5.4. Dimensionamiento de la red

En general, tres capas son suficientes. Hay veces, sin embargo, en que parece que un problema es más fácil de resolver con más de una capa oculta. En este caso, *más fácil* quiere decir que la red aprende más deprisa.

El tamaño de la capa de entrada suele venir dictado por la naturaleza de la aplicación. A menudo, es posible determinar el número de nodos de salida decidiendo si se desea valores analógicos o valores binarios en las unidades de salida.

Determinar el número de unidades que hay que utilizar en la capa oculta no suele ser tan evidente como lo es para las capas de entrada y de salida. La idea principal consiste en utilizar el menor número posible de unidades en la capa oculta, por que cada unidad supone una carga para la computadora durante las simulaciones. Por supuesto, en un sistema que este construido el hardware en su totalidad (Un procesador por cada elemento de proceso), la carga adicional para la computadora no es un factor tan importante (sin embargo, la comunicación entre procesadores puede ser el problema) (Freeman & Skapura, 1993).

La pregunta de cómo escoger el número de neuronas en la capa intermedia y la pregunta más general, como escoger la estructura del perceptrón multicapa, son difíciles. Si los datos de entrenamiento establecidos están aglomerados en grupos con rasgos similares, el número de esos grupos pueden ser usados para escoger el número de neuronas ocultas. En caso extremo, cuando los datos de entrenamiento son escasos y no tienen ningún rasgo en común, entonces el número de conexiones puede necesitar estar cerca al número de los ejemplos de entrenamiento con el propósito de que la red alcance convergencia. Hay muchas sugerencias acerca de como escoger el número h de las neuronas ocultas en un perceptrón multicapa.

Por ejemplo, el número mínimo debería ser $h = (p - 1)/(n + 2)$, donde p es el número de ejemplos de entrenamiento y n es el número de entradas de la red. Cuantos más nodos ocultos en una red, más características de datos de entrenamiento serán capturadas, pero más durara el tiempo de procedimiento de aprendizaje.

Otra heurística para escoger el número de nodos ocultos es donde el número de nodos ocultos es igual al número óptimo de agrupaciones difusas. Esta afirmación ha sido probada experimentalmente. Escogiendo el número de capas es también una tarea difícil. Muchos problemas requieren más de una capa oculta para una mejor solución.

Con el propósito de encontrar el mejor modelo de red neuronal, según Ishikawa y Moriyama en 1995, se puede usar una estructura de aprendizaje (olvidable) sin memoria, entonces durante el entrenamiento se eliminan las conexiones con pequeños pesos. Después del entrenamiento,

solamente las conexiones que contribuyen a la tarea son dejadas, así se define el esqueleto del modelo de red neuronal.

Las neuronas capturan relaciones entre los datos del vector de entrada desde un nivel intermedio en una red multicapa. Cuando se resuelve el problema de paridad, por ejemplo, la activación de las neuronas intermedias reflejan el número de 1's en el vector de entrada. Las neuronas ocultas especializadas en el entrenamiento reaccionan a ciertos rasgos en el entrenamiento de datos, dichos rasgos pudieran no ser conocidos de antemano. La capa intermedia aprende y captura estructuras, agrupaciones, "ajustamientos" y reglas en el entrenamiento de datos (Kasabov, 1998).

3.5.5. Pesos y parámetros de aprendizaje

Los pesos deberían recibir valores iniciales pequeños y aleatorios (± 0.5), al igual que los términos de tendencia, θ_i , que aparecen en las ecuaciones de la entrada neta a cada unidad. Se suele tratar este valor de tendencia como a un peso más, que esta conectado a una unidad ficticia cuya salida siempre es uno.

La selección de un valor para el parámetro de velocidad de aprendizaje, η , tiene un efecto significativo en el rendimiento de la red. Normalmente, η debe ser un número pequeño (del orden de 0.05 a 0.25) para asegurar que la red llegue a asentarse en una solución. Un valor pequeño de η significa que la red tendrá que hacer un gran número de iteraciones pero este es el coste en el que se incurre. Suele ser posible incrementar el valor de η a medida que progresa el aprendizaje. Aumentando a medida que disminuye el error de la red suele acelerar la convergencia incrementando el tamaño del paso conforme el error alcanza un valor mínimo, pero la red puede rebotar, alejándose demasiado del valor mínimo verdadero, si η llegara a ser demasiado grande.

4. MARCO APLICATIVO

En este capítulo se diseña el modelo de red neuronal para desarrollar el prototipo tomando en cuenta los objetivos iniciales del presente trabajo bajo el método ágil Iconix, que considera las interfaces, casos de uso, casos de uso expandidos, diagrama de robustez y el diagrama de clases.

En el presente capítulo se mostrara el diseño del Sistema Neuronal de Reconocimiento de Copépodos, (SINERCO), que esta desarrollado con el modelo ágil Iconix, este sistema es la herramienta principal mediante la cual se lograran los objetivos establecidos para el presente trabajo.

4.1. MODELO DE RED NEURONAL

4.1.1 Descripción del sistema

Para reconocer una especie de copépodo se realiza lo siguiente:

1. La red neuronal artificial capta la imagen.
2. Una vez captada la imagen es convertida en una matriz, debido a que MatLab trabaja en estos términos.
3. Ahora que la imagen es una matriz MatLab, y para poder realizar el reconocimiento esta imagen se transforma en una imagen de escala de grises.
4. Después y para que la imagen este en términos comprensibles para el reconocimiento en blanco y negro.
5. Finalmente la imagen esta en una matriz en código binario para ser procesada y reconocida.
6. Se lleva la matriz binaria a un vector columna, el numero de elementos es igual al numero de nodos de entrada de la red neuronal.
7. Una vez que los datos están listos para ingresar a la red neuronal son procesados y devuelven las salidas diseñadas.

Estos pasos se pueden visualizar en la figura 4.1.

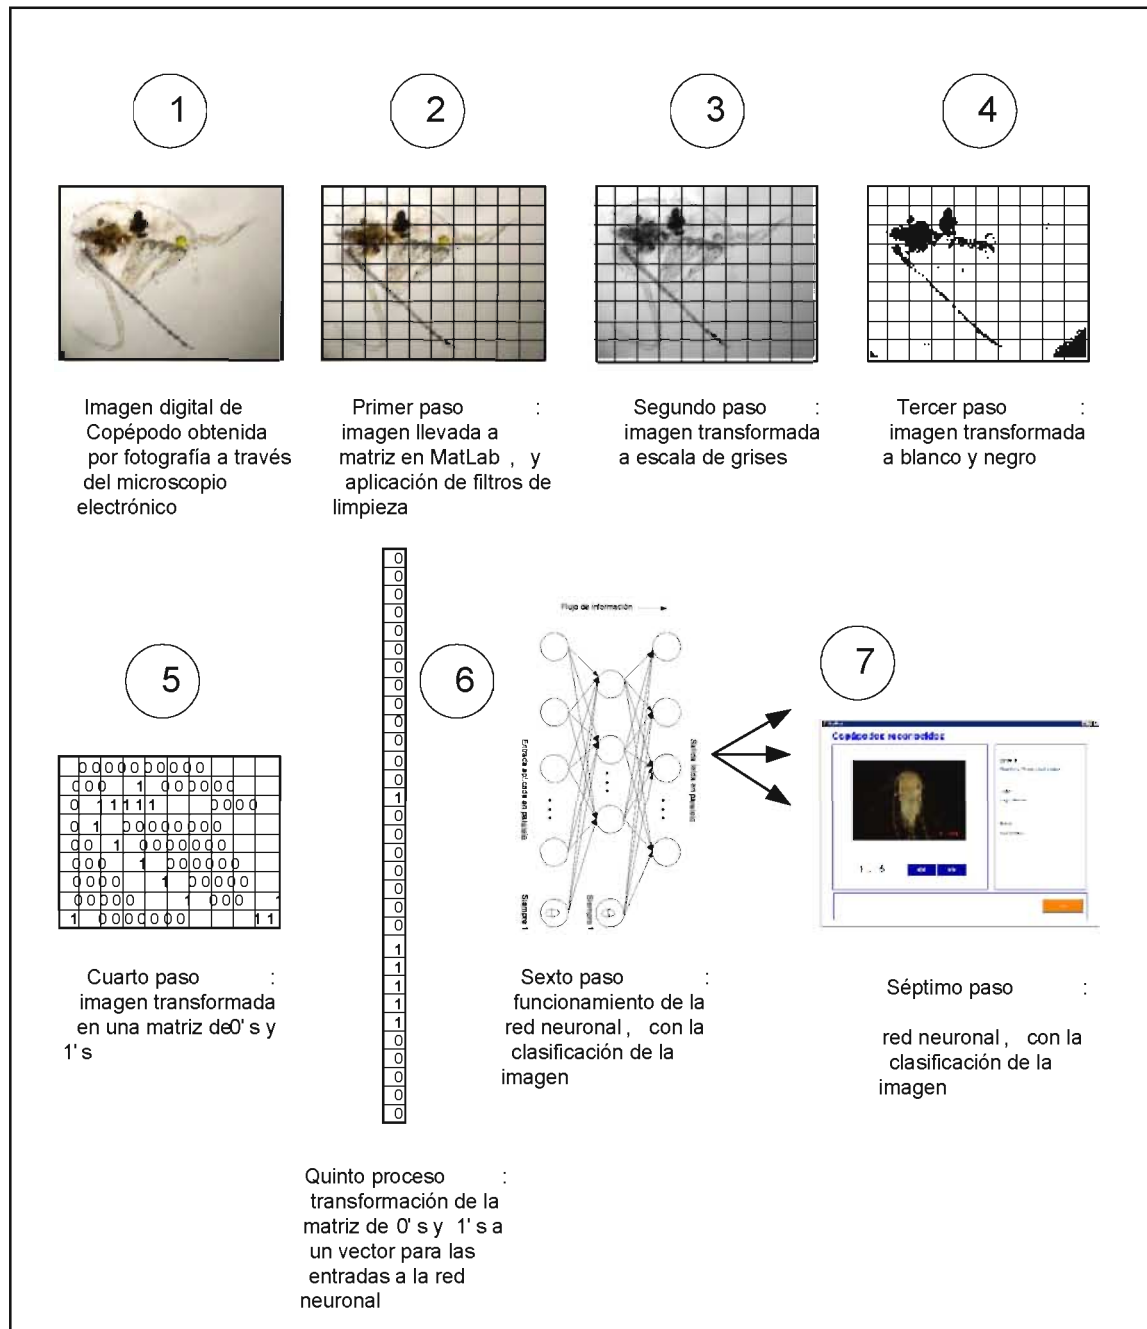


Figura 4.1: Descripción del procedimiento
Fuente: Elaborado según (Hilera y Martínez, 2005)

Debido a la cantidad de datos de entrada se utilizan dos capas ocultas ya que se adecuan a cualquier función.

En la Figura 4.2 la primera capa oculta y la segunda capa oculta tienen funciones de transferencia tangente sigmoideal (*tansig*) porque son las más utilizadas para resolver funciones continuas, y la función de transferencia de la capa de salida es sigmoideal (*logsig*) debido a que los resultados esperados se limitan a dos respuestas “sí” o “no”, en términos numéricos 1 o 0.




Figura 4.2: Modelo de la Red Neuronal
Fuente: Elaborado según (Choque, Loza & Méndez, 2006)

4.1.2. Especificación del diseño

a) Abstracción de datos

En la siguiente tabla se muestran los datos usados en la red neuronal:

Tabla 4.1. Datos usados en la red neuronal
Elaborado según (Choque, Loza & Méndez, 2006)

Atributo	Valor	Tipo	Tamaño
P	{0,1}	NZ^+	9
$IW\{1,1\}$	[-1,1]	R^+	9.99
$LW\{2,1\}$	[-1,1]	R^+	9.99
$LW\{3,2\}$	[-1,1]	R^+	9.99
T	[0,1]	NZ^+	9
$A\{1\}$	[-1,1]	R^+	9.99
$A\{2\}$	[-1,1]	R^+	9.99
$A\{3\}$	[0,1]	R^+	9.99
$B\{1\}$	[-1,1]	R^+	9.99
$B\{2\}$	[-1,1]	R^+	9.99
$B\{3\}$	[-1,1]	R^+	9.99

b) Abstracción procedimental

Para la abstracción procedimental se utiliza el asociado el algoritmo 4.1.

Algoritmo_Backpropagation_sinerco ()

- P1: Leer imagen I*
- P2: Convertir la imagen I en matriz*
- P3: Cambiar el tamaño de la imagen I a 300x300 píxeles*
- P4: Uniformar el color del fondo de la imagen I*
- P5: Aplicar el filtro para transformar la matriz en escala de grises*
- P6: Detectar los bordes de la imagen I*
- P7: Transformar la imagen I a un vector de entrada P*
- P8: Aplicar normalización de los patrones de entrada P*
- P9: Definir la topología de la red perceptrón multicapa*
- P10: Definir los parámetros para el entrenamiento*
- P11: Entrenar la red*
- P12: Validar el funcionamiento de la red*

FIN_ Algoritmo_Backpropagation_sinerco

Algoritmo 4.1: Retropropogación Copépodos
Elaborado según (Choque, Loza & Méndez, 2006)

4.2. ANÁLISIS Y DISEÑO DEL PROTOTIPO

4.2.1 Requerimientos funcionales

1. Realizar procesamiento de imágenes
2. Reconocer imágenes fotográficas de copépodos
3. Clasificar de imágenes fotográficas de copépodos
4. Registrar los resultados
5. Monitorear los duplicados
6. Desplegar imagen filtrada
7. Identificar usuarios

4.2.2 Actores

1. **Investigador.-** Se encarga de obtener la imagen o el lote de imágenes de los copépodos mediante el microscopio, luego debe llevar la misma o dicho lote a la computadora y después guardarlas.
2. **Administrador del sistema.-** Se encarga de revisar los registros del sistema, eliminar los datos que no son productivos, trabajar en base a las imágenes reconocidas y habilitar nuevos usuarios.

4.2.3. Diseño de Interfaces

4.2.3.1. Autentificador

La primera interfaz que ven los usuarios del sistema es la interfaz de autenticación la encargada de recibir los datos que serán corroborados Figura 4.3.

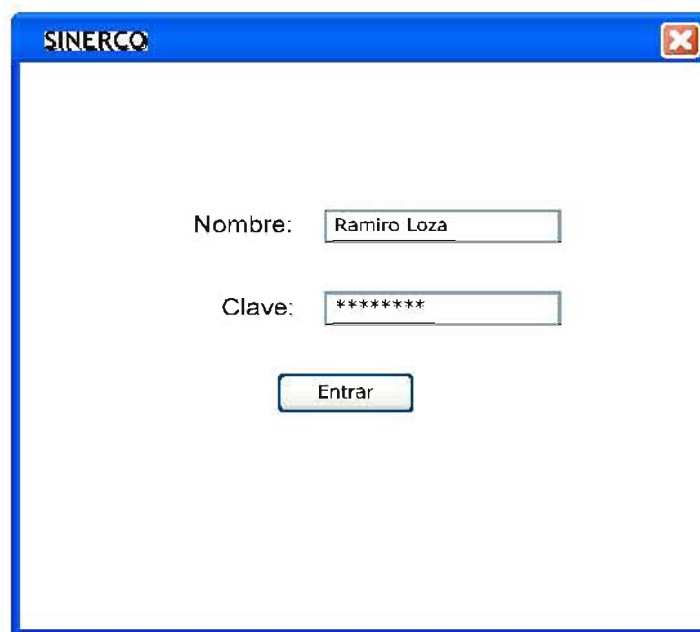


Figura 4.3: Interfaz del autenticador

Fuente: Prototipo Sistema Neuronal de Reconocimiento de Copépodos (SINERCO)

4.2.3.2. Interfaz principal

Una vez que el investigador o el administrador del sistema ingresen al sistema podrán trabajar con el mismo, con las opciones mostradas en la Figura 4.4.

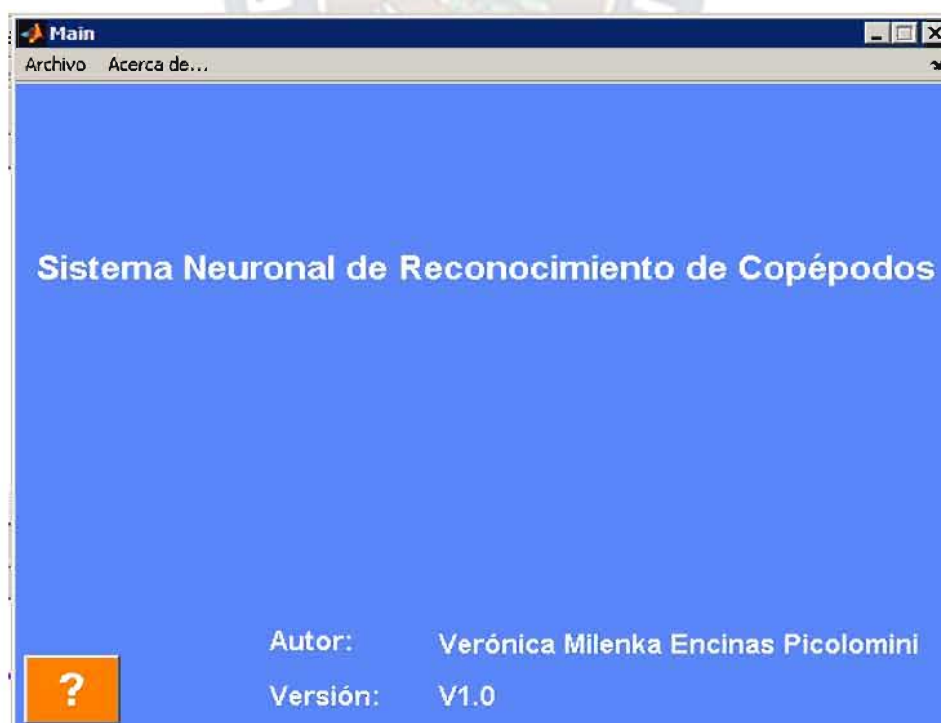


Figura 4.4: Interfaz principal

Fuente: Prototipo SINERCO

4.2.3.3. Reconocimiento de imagen

Después de examinar y encontrar la imagen que se busca sea reconocida esta es cargada en la interfaz, con la opción de poder ser reconocida y almacenada (figura 4.5.).



The screenshot shows a software window titled "RecCop" with a sub-header "Reconocimiento de Copépodos". On the left, there is a large image of a copepod. Below the image are two blue buttons: "Abrir Imagen" and "Reconocer". On the right, there are three input fields labeled "Especie:", "Lugar:", and "Autor:", each followed by a text entry box. Below these fields is a blue button labeled "Guardar". At the bottom right of the window is an orange button labeled "Salir".

Figura 4.5: Interfaz de reconocimiento de copépodos
Fuente: Prototipo SINERCO

4.2.3.4. Ver registros

La opción de ver registros permite a los usuarios de sistema ver resultados obtenidos anteriormente de la forma mostrada en la figura 4.6.



Figura 4.6: Interfaz copépodos reconocidos
Fuente: Prototipo SINERCO

4.2.4. Casos de uso para los requerimientos funcionales

Estas son las funcionalidades del sistema (figura 4.7).

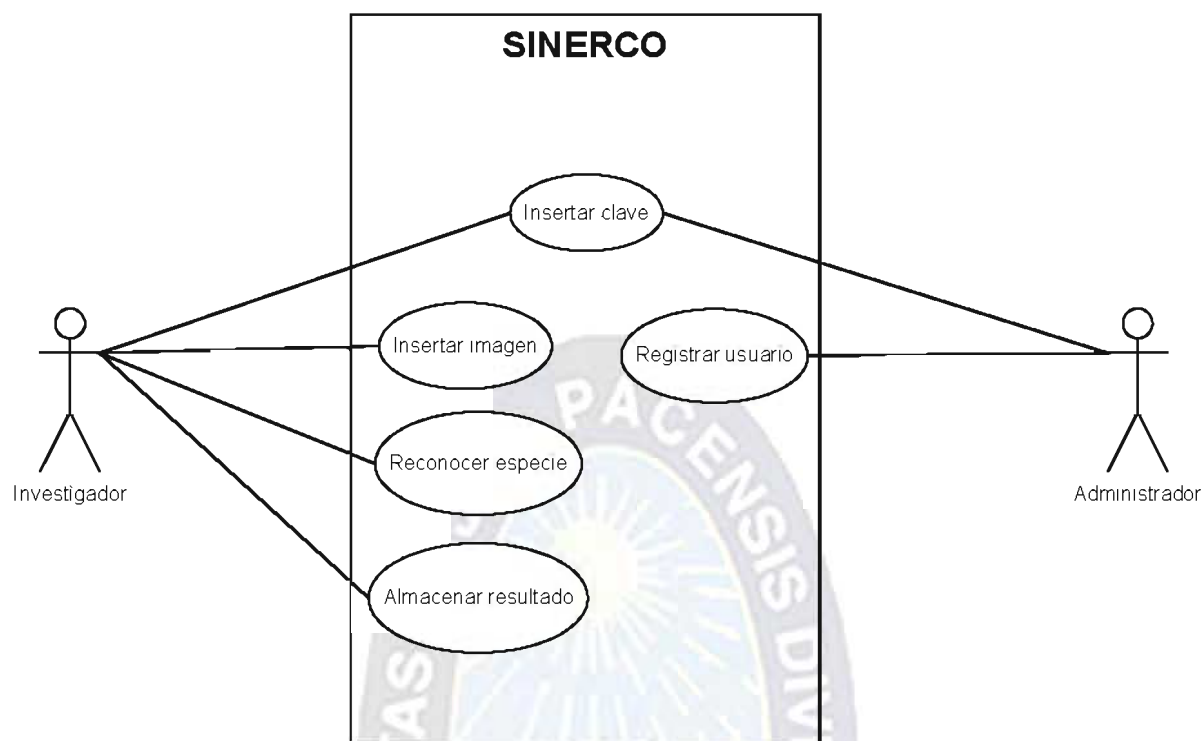


Figura 4.7: Casos de uso de Sinerco
Fuente: Elaborado según (Schmuller, 2003)

4.2.5. Casos de uso expandidos

CASO DE USO: Registrar usuario

NIVEL: Función del sistema

ACTOR PRINCIPAL: Administrador

PARTES INTERESADAS:

- **Investigador:** Informa datos personales al administrador.
- **Administrador:** Recibe los datos y los lleva al sistema.

PROPÓSITO: Registrar investigadores para el reconocimiento de copépodos.

PRECONDICIONES: El administrador ingresa al “Sistema Neuronal de Reconocimiento de Copépodos” y cuenta con los datos referidos a un investigador.

POST - CONDICIONES: El administrador verifica si existen más investigadores de la unidad de Limnología, para ser registrados.

FLUJO BÁSICO:

ACCIÓN DEL ACTOR

1. El caso de uso comienza cuando el administrador elige la opción “Registrar usuario”.
3. Llena los datos del investigador
4. Acepta los datos

RESPONSABILIDAD DEL SISTEMA

2. Muestra la interfaz “Investigador”
5. Despliega mensaje de confirmación de datos introducidos y pregunta si desea añadir un nuevo registro.

6. Administrador no registra más usuarios

FLUJO ALTERNATIVO:

5a. Falta llenar una o más casillas de texto:

El sistema despliega un mensaje indicando que falta llenar datos y retorna al paso 2 con los datos llenados anteriormente.

6a. Existe más de un usuario:

El administrador indica que desea añadir otro usuario, retorna al paso 2.

REQUERIMIENTOS ESPECIALES:

No se identificaron

LISTA DE VARIACIÓN DE DATOS Y TECNOLOGÍA:

No se identifico

CASO DE USO: Insertar clave

NIVEL: Función del sistema

ACTOR PRINCIPAL: Administrador

PARTES INTERESADAS:

- **Investigador:** Necesita ingresar al sistema y poseer una clave.
- **Administrador:** Necesita registrar investigadores

PROPÓSITO: Ingresar al sistema.

PRECONDICIONES: El administrador intenta entrar al “Sistema Neuronal de Reconocimiento de Copépodos” y la base de datos tiene registrado al administrador. La primera pagina del mismo muestra los campos nombre y clave.

POST - CONDICIONES: El administrador ingresa al sistema.

FLUJO BÁSICO:

ACCIÓN DEL ACTOR

1. Digita su nombre y su clave
4. Ingresa al sistema

RESPONSABILIDAD DEL SISTEMA

2. Verifica los datos del administrador
 3. Comprueba los datos y permite ingreso
-

FLUJO ALTERNATIVO:

3a. No encuentra los datos del administrador y el permiso es denegado.

4a. No ingresa al sistema

REQUERIMIENTOS ESPECIALES:

El administrador debe tener su nombre de usuario y su clave registradas en la base de datos.

LISTA DE VARIACIÓN DE DATOS Y TECNOLOGÍA:

No se identifico

CASO DE USO: Insertar clave

NIVEL: Función del sistema

ACTOR PRINCIPAL: Investigador

PARTES INTERESADAS:

- **Investigador:** Necesita ingresar al sistema para reconocer las especies de

copépodos.

- **Administrador:** Necesita tener resultados de las muestras de copépodos, necesita el reconocimiento de las especies.

PROPÓSITO: Ingresar al sistema.

PRECONDICIONES: El investigador intenta entrar al “Sistema Neuronal de Reconocimiento de Copépodos” y la base de datos tiene registrado al investigador.

POST - CONDICIONES: El investigador ingresa al sistema

FLUJO BÁSICO:

ACCIÓN DEL ACTOR

1. El caso de uso comienza cuando el investigador elige la opción “Insertar clave”.
3. Digita su nombre y su clave

RESPONSABILIDAD DEL SISTEMA

2. Muestra la interfaz “Insertar clave”
4. Verifica los datos del investigador
5. Comprueba los datos y permite ingreso

6. Ingresar al sistema

FLUJO ALTERNATIVO:

5a. No encuentra los datos del investigador y el permiso es denegado.

6a. No ingresa al sistema

REQUERIMIENTOS ESPECIALES:

El investigador debe tener su nombre de usuario y su clave registradas en la base de datos.

LISTA DE VARIACIÓN DE DATOS Y TECNOLOGÍA:

No se identificó

CASO DE USO: Insertar imagen

NIVEL: Función del sistema

ACTOR PRINCIPAL: Investigador

PARTES INTERESADAS:

- **Investigador:** Está interesado en reconocer las especies de copépodos.
- **Administrador:** Está interesado en obtener el reconocimiento de especies de copépodos.

PROPÓSITO: Encontrar la imagen o lote de imágenes que requiere el investigador

PRECONDICIONES: La imagen se encuentra en la computadora.

POST - CONDICIONES: Imagen o lote de imágenes cargado en la computadora.

FLUJO BÁSICO:

ACCIÓN DEL ACTOR

1. El caso de uso comienza cuando el investigador hace clic en el botón “Insertar imagen”.
3. Hace clic en “examinar”
5. Elige la dirección y acepta

RESPONSABILIDAD DEL SISTEMA

2. Muestra la interfaz “Cargar imagen”
4. Muestra una interfaz para buscar la dirección del archivo
6. Carga datos desde el archivo especificado
7. Actualiza la interfaz “Cargar imagen”

9. Hace clic en “Aceptar”

8. Muestra la interfaz “Cargar imagen”

10. Cierra la ventana “Cargar imagen” y
Muestra la interfaz principal

FLUJO ALTERNATIVO:

5a. Investigador cancela la búsqueda de archivo:

El sistema muestra la interfaz principal

REQUERIMIENTOS ESPECIALES:

La imagen debe estar en la computadora

LISTA DE VARIACIÓN DE DATOS Y TECNOLOGÍA:

No se identifico

CASO DE USO: Reconocer especie

NIVEL: Función del sistema

ACTOR PRINCIPAL: Investigador

PARTES INTERESADAS:

- **Investigador:** Esta interesado en reconocer las especies de copépodos.
- **Administrador:** Esta interesado en obtener el reconocimiento de especies de copépodos.

PROPÓSITO: Procesar la imagen o lote de imágenes que requiere el investigador

PRECONDICIONES: La imagen ya fue cargada.

POST – CONDICIONES: Logra procesar la imagen y obtener un resultado.

FLUJO BÁSICO:

ACCIÓN DEL ACTOR

1. El caso de uso comienza cuando el investigador hace clic en el botón “Reconoce especie”.

RESPONSABILIDAD DEL SISTEMA

2. Aplica filtros a la imagen
3. Aplica la red neuronal
4. Encuentra la especie de copépodo correspondiente.
5. Muestra la interfaz principal

6. Visualiza la interfaz principal con el resultado obtenido.

FLUJO ALTERNATIVO:

2a. La imagen no es útil para el proceso.

4b. No encuentra la especie de copépodo

REQUERIMIENTOS ESPECIALES:

La imagen debe estar en cargada

LISTA DE VARIACIÓN DE DATOS Y TECNOLOGÍA:

No se identifico

CASO DE USO: Almacenar resultado

NIVEL: Función del sistema

ACTOR PRINCIPAL: Investigador

PARTES INTERESADAS:

- **Investigador:** Esta interesado en reconocer las especies de copépodos.
- **Administrador:** Esta interesado en obtener el reconocimiento de especies de copépodos.

PROPÓSITO: Almacenar el resultado obtenido.

PRECONDICIONES: La imagen ya fue procesada

POST – CONDICIONES: Logra almacenar resultado.

FLUJO BÁSICO:

ACCIÓN DEL ACTOR

RESPONSABILIDAD DEL SISTEMA

1. El caso de uso comienza cuando el investigador hace clic en el botón “Almacenar resultado”.

3. Llena los datos correspondientes

7. Acepta almacenar el resultado.

2. Muestra la interfaz almacenamiento

4. Acepta los datos

5. Guarda el resultado.

6. Envía mensaje de confirmación

FLUJO ALTERNATIVO:

4a. No acepta los datos introducidos.

5a. No guarda el resultado

6ª. Envía mensaje de denegación

REQUERIMIENTOS ESPECIALES:

La imagen debe estar preprocesada

4.2.6. Diagrama de secuencias

4.2.6.1. Insertar clave

La figura 4.8, muestra de forma explicativa lo que sucede cuando el usuario del sistema inserta su clave.



Figura 4.8: Diagrama de secuencia “insertar clave”
Fuente: Elaborado según (Schmuller, 2003)

4.2.6.2. Registrar usuario

El administrador es la persona encargada de las altas y bajas del sistema, una vez que es validada su clave puede conceder nuevas claves para nuevos investigadores (figura 4.9.).



Figura 4.9: Diagrama de secuencia “Registrar usuario”
Fuente: Elaborado según (Schmuller, 2003)

4.2.6.3. Insertar imagen

El diagrama de secuencias para insertar imagen muestra los pasos detallados que el investigador debe seguir para insertar la imagen que espera sea reconocida figura 4.10.

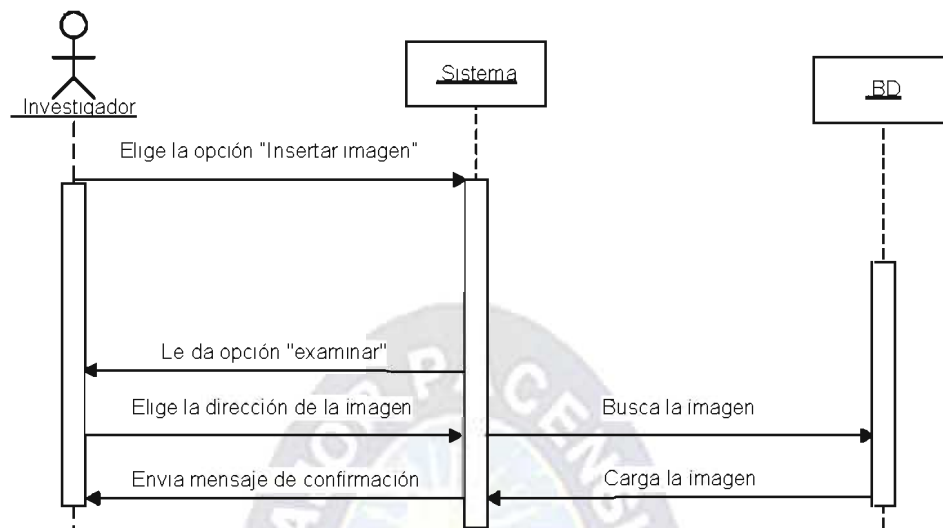


Figura 4.10: Diagrama de secuencia “insertar clave”
Fuente: Elaborado según (Schmuller, 2003)

4.2.6.4. Reconocer especie

Para procesar la imagen es decir para que la fotografía sea reconocida se aplican los pasos del diagrama de secuencia de la figura 4.11.

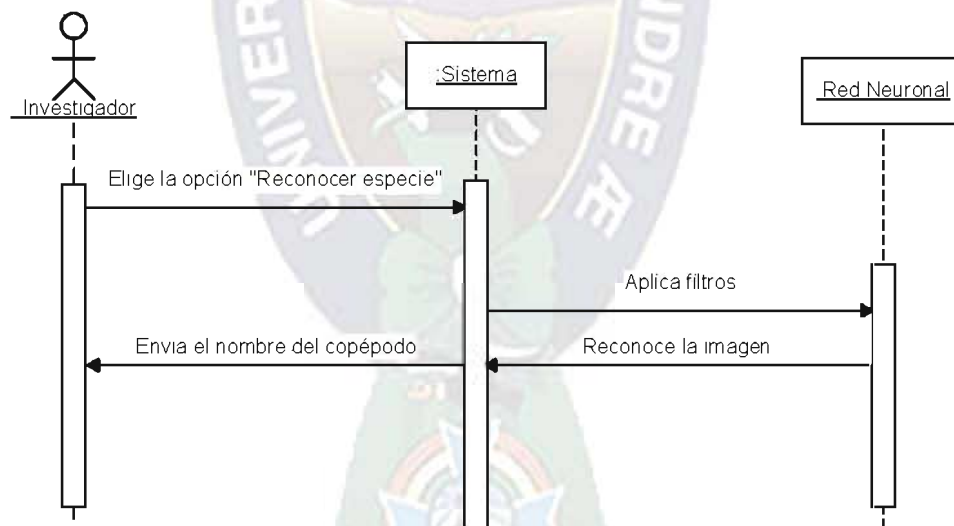


Figura 4.11: Diagrama de secuencia “Reconocer especie”
Fuente: Elaborado según (Schmuller, 2003)

4.2.6.5. Almacenar resultado

Es útil que después de que se reconozca una imagen estos datos no se pierdan y se queden guardados para una futura investigación (figura 4.12).

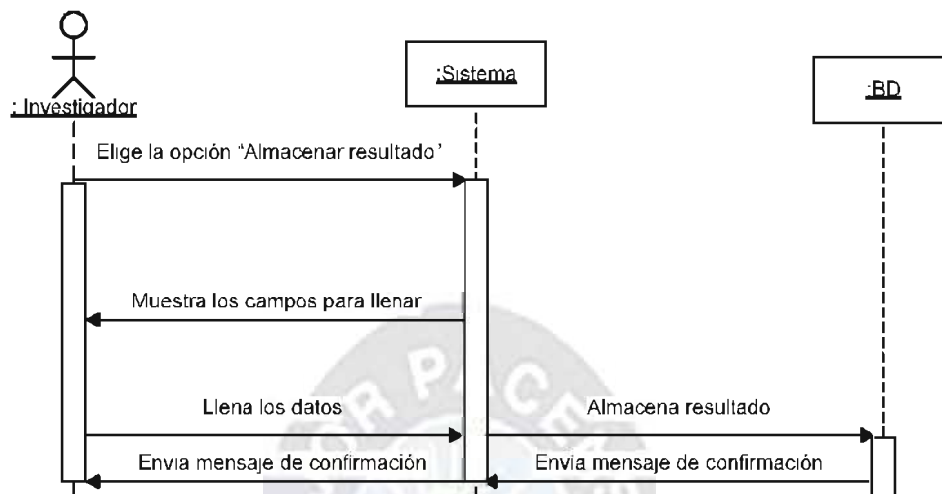


Figura 4.12: Diagrama de secuencia “Almacenar resultado”
Fuente: Elaborado según (Schmuller, 2003)

4.2.7. Diagrama de robustez

4.2.7.1. Insertar clave

A continuación en la figura 4.13 se muestra como el sistema responde a la solicitud “insertar clave”.

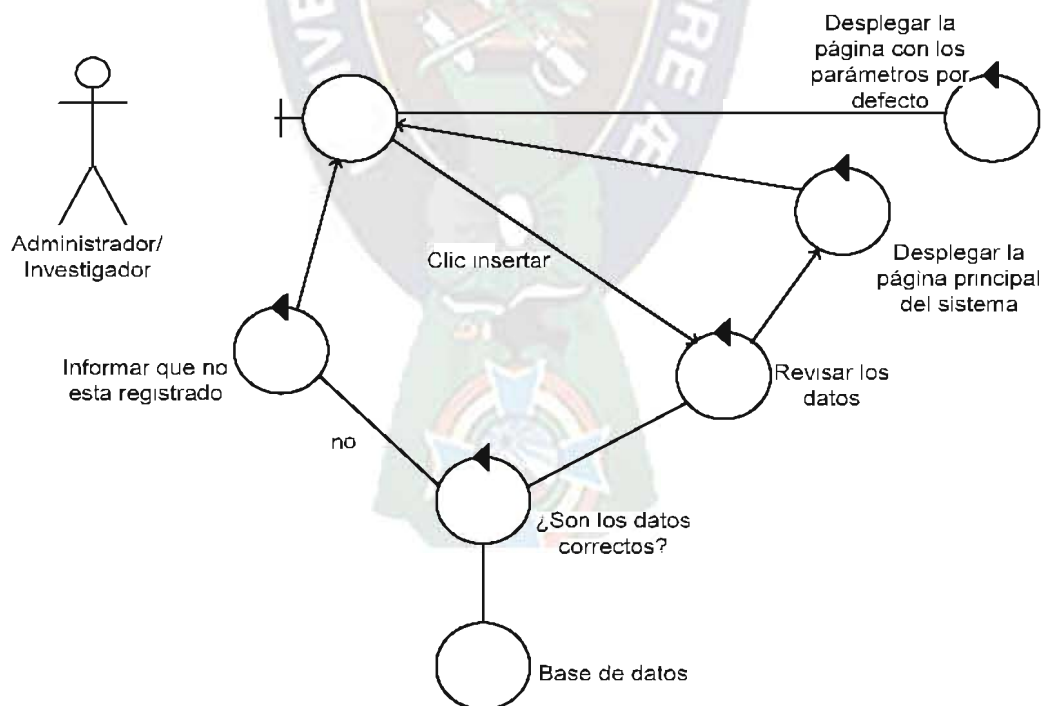


Figura 4.13: Diagrama de robustez “insertar clave”
Fuente: Elaborado según (Rosenberg D. & Stephens M. & Collins-Cope M. , 2005)

4.2.7.2. Reconocer especie

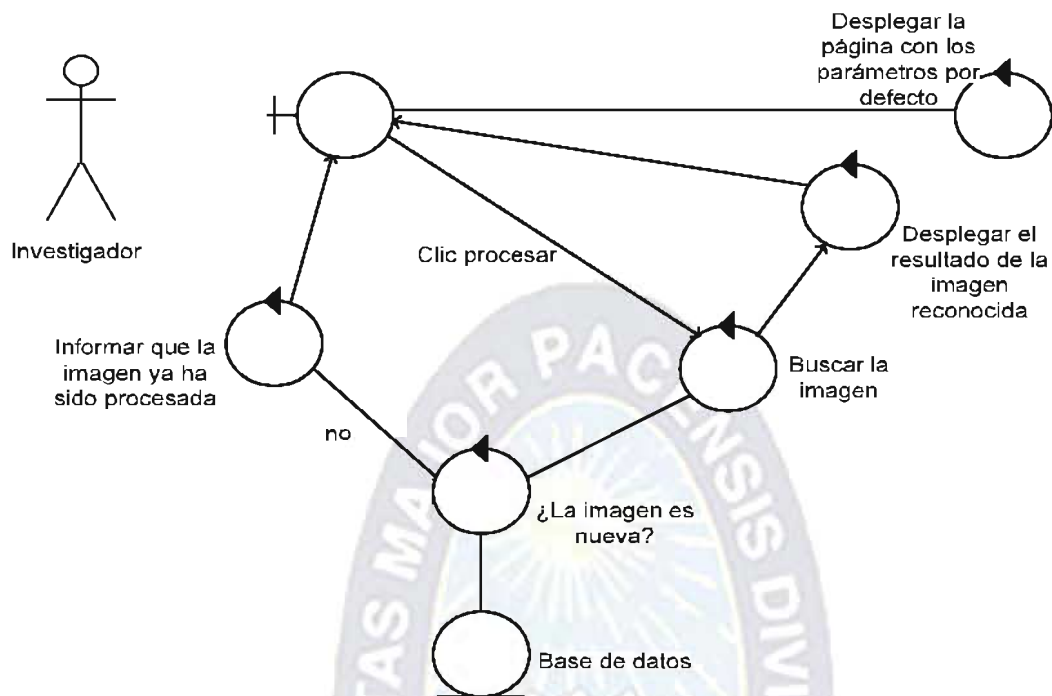


Figura 4.14: Diagrama de robustez "Reconocer especie"

Fuente: Elaborado según (Rosenberg D. & Stephens M. & Collins-Cope M. , 2005)

4.2.7.3. Almacenar resultado

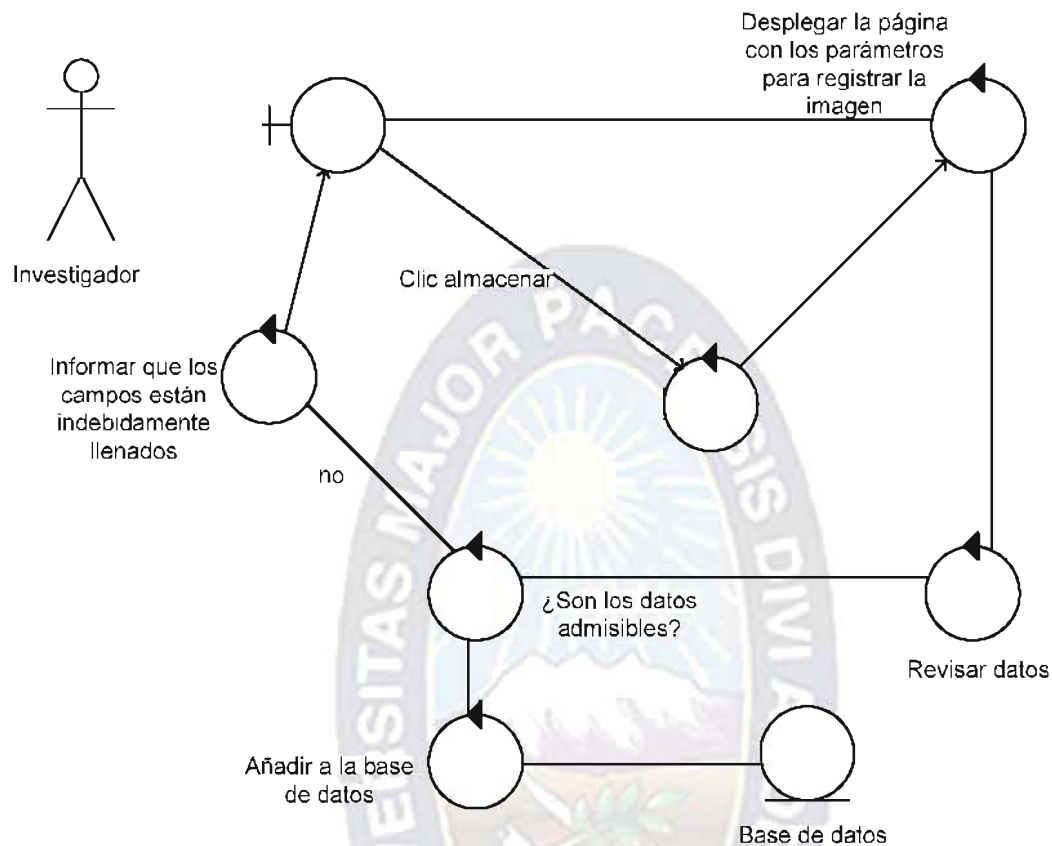


Figura 4.15: Diagrama de robustez "Almacenar resultado"

Fuente: Elaborado según (Rosenberg D. & Stephens M. & Collins-Cope M. , 2005)

4.2.7.4. Registra usuario

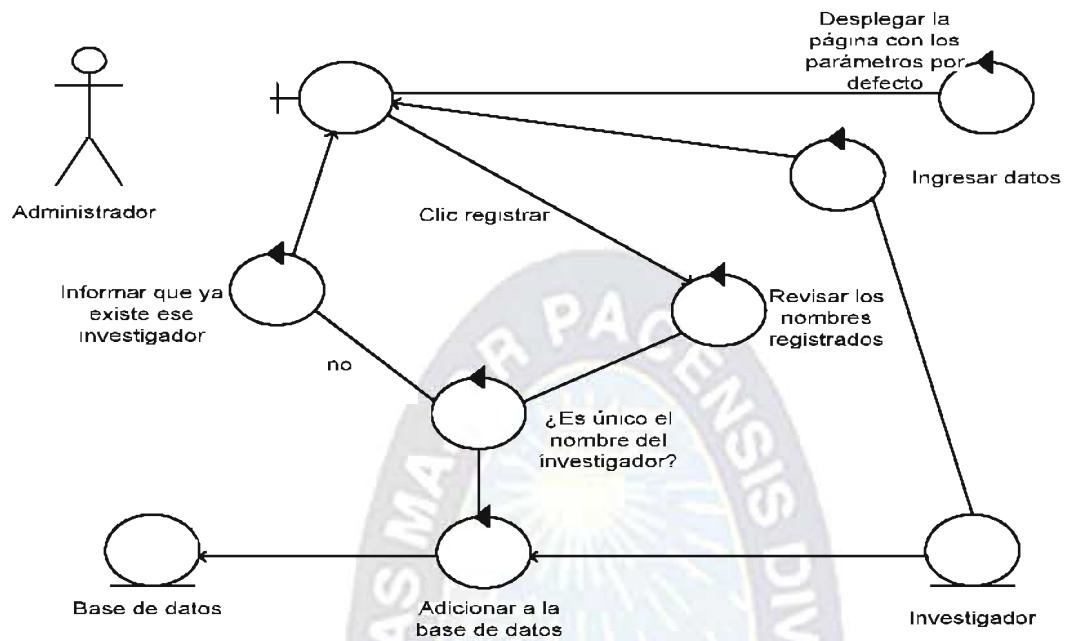


Figura 4.16: Diagrama de robustez "registra usuario"

Fuente: Elaborado según (Rosenberg D. & Stephens M. & Collins-Cope M. , 2005)

4.2.7.5. Insertar imagen




Figura 4.17: Diagrama de robustez "insertar imagen"

Fuente: Elaborado según (Rosenberg D. & Stephens M. & Collins-Cope M. , 2005)

4.2.8. Diagrama de clases

El presente diagrama de clases (figura 4.18.) muestra a las entidades involucradas en el sistema Sinerco.




Figura 4.18: Diagrama de clases
Fuente: Elaborado según (Schmuller, 2003)

5. PRUEBAS Y MÉTRICAS DE CALIDAD

RESUMEN

En este capítulo se muestran las pruebas que fueron usadas para verificar la capacidad del prototipo, también se aplican las métricas de calidad correspondientes para un prototipo desarrollado bajo los conceptos de la programación orientada a objetos.

5.1. PRUEBAS PARA EL RECONOCIMIENTO DE LAS ESPECIES DE COPÉPODOS

Para comprobar el buen funcionamiento del prototipo se realizaron pruebas con 15 entradas para cada una de las 3 salidas, en la tabla 5.1 se presenta las salidas deseadas, las salidas obtenidas con el prototipo, seguidas por el error en los tres nodos de salida, después se indica el error total y por último el error promedio.

También se muestra la suma total del error y el error promedio de todas las pruebas realizadas, el valor del error obtenido en las pruebas es de 0,176 este valor indica que del 100% de las pruebas 17,6 % estuvieron erróneas.

Tabla 5.1: Resultados de la prueba para el reconocimiento de copépodos

Nro.	Salidas deseadas	Salida obtenida nodo 1	Salida obtenida nodo 2	Salida obtenida nodo 3	Error nodo 1	Error nodo 2	Error nodo 3	Error total	Error Promedio
1	[1 0 0]	1,000	0,033	0,041	0,000	0,033	0,041	0,075	0,025
2	[1 0 0]	0,938	0,103	0,917	-0,062	0,103	0,917	0,957	0,319
3	[1 0 0]	0,952	0,058	0,925	-0,048	0,058	0,925	0,934	0,311
4	[1 0 0]	1,000	0,025	0,053	0,000	0,025	0,053	0,078	0,026
5	[1 0 0]	0,999	0,097	0,086	-0,001	0,097	0,086	0,182	0,061
6	[1 0 0]	1,000	0,031	0,066	0,000	0,031	0,066	0,097	0,032
7	[1 0 0]	1,000	0,051	0,029	0,000	0,051	0,029	0,079	0,026
8	[1 0 0]	1,000	0,085	0,035	0,000	0,085	0,035	0,120	0,040
9	[1 0 0]	1,000	0,063	0,026	0,000	0,063	0,026	0,089	0,030
10	[1 0 0]	1,000	0,078	0,035	0,000	0,078	0,035	0,112	0,037
11	[1 0 0]	1,000	0,029	0,107	0,000	0,029	0,107	0,135	0,045
12	[1 0 0]	1,000	0,018	0,135	0,000	0,018	0,135	0,152	0,051
13	[1 0 0]	0,883	0,137	0,974	-0,117	0,137	0,974	0,993	0,331
14	[1 0 0]	1,000	0,041	0,011	0,000	0,041	0,011	0,052	0,017
15	[1 0 0]	0,916	0,096	0,960	-0,084	0,096	0,960	0,972	0,324
16	[0 1 0]	0,189	0,940	0,203	0,189	-0,060	0,203	0,332	0,111
17	[0 1 0]	0,946	0,056	0,938	0,946	-0,944	0,938	0,941	0,314
18	[0 1 0]	0,910	0,059	0,976	0,910	-0,941	0,976	0,945	0,315
19	[0 1 0]	0,903	0,174	0,913	0,903	-0,826	0,913	0,990	0,330
20	[0 1 0]	0,938	0,257	0,715	0,938	-0,743	0,715	0,910	0,303
21	[0 1 0]	0,924	0,334	0,945	0,924	-0,666	0,945	1,203	0,401
22	[0 1 0]	0,124	0,835	0,453	0,124	-0,165	0,453	0,412	0,137
23	[0 1 0]	0,934	0,064	0,937	0,934	-0,936	0,937	0,935	0,312

24	[0 1 0]	0,739	0,058	0,986	0,739	-0,942	0,986	0,783	0,261
25	[0 1 0]	0,837	0,073	0,983	0,837	-0,927	0,983	0,893	0,298
26	[0 1 0]	0,979	0,120	0,880	0,979	-0,880	0,880	0,979	0,326
27	[0 1 0]	0,168	0,925	0,247	0,168	-0,075	0,247	0,340	0,113
28	[0 1 0]	0,874	0,025	0,930	0,874	-0,975	0,930	0,829	0,276
29	[0 1 0]	0,930	0,069	0,934	0,930	-0,931	0,934	0,933	0,311
30	[0 1 0]	0,831	0,193	0,933	0,831	-0,807	0,933	0,957	0,319
31	[0 0 1]	0,039	0,039	0,997	0,039	0,039	-0,003	0,075	0,025
32	[0 0 1]	0,045	0,021	0,998	0,045	0,021	-0,002	0,063	0,021
33	[0 0 1]	0,029	0,022	0,998	0,029	0,022	-0,002	0,049	0,016
34	[0 0 1]	0,032	0,031	0,997	0,032	0,031	-0,003	0,060	0,020
35	[0 0 1]	0,026	0,161	0,999	0,026	0,161	-0,001	0,187	0,062
36	[0 0 1]	0,508	0,025	0,997	0,508	0,025	-0,003	0,530	0,177
37	[0 0 1]	0,343	0,027	0,999	0,343	0,027	-0,001	0,368	0,123
38	[0 0 1]	0,937	0,019	0,328	0,937	0,019	-0,672	0,283	0,094
39	[0 0 1]	0,981	0,076	0,716	0,981	0,076	-0,284	0,773	0,258
40	[0 0 1]	0,972	0,042	0,949	0,972	0,042	-0,051	0,963	0,321
41	[0 0 1]	0,082	0,064	0,996	0,082	0,064	-0,004	0,142	0,047
42	[0 0 1]	0,709	0,720	0,929	0,709	0,720	-0,071	1,358	0,453
43	[0 0 1]	0,050	0,051	0,998	0,050	0,051	-0,002	0,099	0,033
44	[0 0 1]	0,074	0,082	0,998	0,074	0,082	-0,002	0,155	0,052
45	[0 0 1]	0,888	0,333	0,985	0,888	0,333	-0,015	1,207	0,402
TOTAL								23,722	7,907
PROMEDIO								0,527	0,176

La tabla 5.2 es un resumen de las pruebas que se realizaron para el prototipo, presenta una conclusión acerca de las pruebas la cual muestra que la salida del nodo 2 tiene mayor error en el reconocimiento. Afortunadamente la red neuronal artificial es modificable lo cual indica que estos datos podrían mejorar en un futuro.

Tabla 5.2: Resultados de la prueba para el reconocimiento de copépodos

Salidas deseadas	Número de pruebas	Aciertos	Errados
[1 0 0]	15	13	2
[0 1 0]	15	3	12
[0 0 1]	15	12	3
TOTAL	45	28	17
PORCENTAJE		62	38

5.2. MÉTRICAS DE CALIDAD ORIENTADAS A OBJETOS DEL PROTOTIPO

En la evaluación de calidad del prototipo se tomarán en consideración los siguientes puntos que son importantes en la programación orientada a objetos.

1. Tamaño de clase
2. Acoplamiento entre clases objetos
3. Carencia de cohesión en los métodos
4. Respuesta para una clase

5.2.1. Tamaño de clase

Sinerco es un sistema sencillo y fácil de usar tomando en cuenta en este sentido que la cantidad de métodos por clase para este prototipo es la siguiente:

Tabla 5.3: Tamaño de clase
Fuente: Elaborado según (Pressman, 2002)

Nombre de Clase	Métodos	Atributos
Investigador	2	3
Copépodo	3	3
Administrador	3	3
Promedio	2.33	3

Según lo que indica la tabla 4 el promedio de responsabilidad por clases en métodos en 2.33% y en los atributos 3%, porcentajes pequeños que permiten la reutilización del prototipo Sinerco.

5.2.2. Acoplamiento entre clases objetos

El acoplamiento ACO entre clases objeto es una medida de la interconexión entre los módulos de una estructura de programa. Depende de la complejidad de la interfaz entre módulos, el punto en el que se entra o se hace referencia al módulo y qué datos pasan a través de la interfaz (Pressman, 2002).

Si ACO es mayor a cinco, las clases son difíciles de comprender, reutilizar y mantener.

Tabla 5.4: Acoplamiento entre clases objeto (ACO)
Fuente: Elaborado según (Pressman, 2002)

Nombre de Clase	ACO
Investigador	2
Copépodo	0
Administrador	2
Promedio	1.33

ACO tiene el valor de 1.33 en el prototipo y es menor a cinco lo que indica que Sinerco tiene una conectividad sencilla entre clases que da como resultado un software fácil de entender y reutilizar.

5.2.3. Carencia de cohesión en los métodos

Un módulo con cohesión realiza una sola tarea dentro de un procedimiento software, requiriendo poca interacción con los procedimientos que se realizan en otras partes del programa. Dicho de una manera sencilla, un módulo con cohesión debería (idealmente) hacer una sola cosa (Pressman, 2002).

La carencia de cohesión en los métodos (CCM), es el número de métodos que acceden a uno o más de los mismos atributos, para el prototipo el valor resultante de este punto resulta:

Tabla 5.5: Carencia de cohesión en los métodos (CCM)
Fuente: Elaborado según (Pressman, 2002)

Nombre de Clase	CCM
Investigador	0
Copépodo	0
Administrador	0
Promedio	0

El resultado obtenido en la tabla 5.5 indica que ningún método accede a los mismos atributos, entonces CCM es 0, lo que significa que el prototipo no presentará efectos colaterales entre las clases.

5.2.4. Respuesta para una clase

El conjunto de respuesta de una clase es “un conjunto de métodos que pueden ser ejecutados potencialmente en respuesta a un mensaje recibido por un objeto de esa clase”

La respuesta para una clase (RPC) se define como el número de métodos existentes en el conjunto de respuestas.

Tabla 5.6: Carencia de cohesión en los métodos (RPC)
Fuente: Elaborado según (Pressman, 2002)

Nombre de Clase	RPC
Investigador	1
Copépodo	2
Administrador	1
Promedio	1.33

El valor 1.33 indica que el prototipo tiene una complejidad mínima, este resultado es el esperado porque se utilizan pocos métodos para reconocer las especies de Copépodos.

6. CONCLUSIONES Y RECOMENDACIONES

RESUMEN

A continuación se describen las conclusiones, la comparación con la hipótesis planteada al inicio del presente trabajo, trabajos futuros que se pueden desarrollar en el futuro y las recomendaciones para los mismos.

6.1. ESTADO DE LOS OBJETIVOS

En el capítulo 1. se plantearon los objetivos de la presente investigación, el objetivo general: *“Clasificar las especies de copépodos existentes en los lagos Titicaca y Poopó mediante un prototipo computarizado basado en redes neuronales utilizando las imágenes fotográficas de los estudios realizados sobre este orden”*, al concluir este trabajo se tiene como resultado que no ha sido posible reconocer “todas” las especies de los lagos Titicaca y Poopó debido a que no se tienen las fotografías de estas especies, porque la obtención de estas implicaría un nuevo viaje y la recolección de nuevas muestras, por tanto para el funcionamiento del sistema se trabajó con las imágenes de los copépodos que se encontraban en el centro de Limnología, que fueron suficientes para trabajar y alcanzar el objetivo de “reconocer” las imágenes mediante una red neuronal artificial.

Para el siguiente objetivo específico *“Obtener imágenes claras de las especies de Copépodos de los lagos Titicaca y Poopó mediante cámaras digitales de microscopios con alta resolución”*, se obtuvieron resultados satisfactorios ya que la cámara usada era SONY cybershot obteniendo imágenes de 2272 x 1704 píxeles.

Los investigadores de biología no consultarán las claves de identificación, y su trabajo se limitará a tomar las fotos a través del microscopio, e introducirlas a la computadora para luego usar el prototipo y de esta forma se logrará el objetivo: *“Evitar consultar las claves de identificación para la clasificación de copépodos, ya que la red neuronal solo necesita trabajar con las imágenes fotográficas”*.

El prototipo demostró trabajar correctamente con las imágenes de prueba, pero aun la red neuronal artificial debe entrenar con las especies restantes para que finalmente se cumpla el objetivo general y demostrar en su lugar de desenvolvimiento que es útil y que puede alcanzar el objetivo específico: *“Reducir el error de las clasificaciones de especies de copépodos, mediante las imágenes fotográficas tomadas del mismo”*.

El prototipo demostró trabajar correctamente con las imágenes de prueba incompletas para alcanzar el objetivo: *“Utilizar la capacidad de generalización de las redes neuronales artificiales para el reconocimiento de copépodos incompletos”* pero se presenta el mismo percance que en el anterior objetivo específico.

En el capítulo 4 Marco Aplicativo en el desarrollo del prototipo se aplicaron los filtros necesarios para que la red neuronal artificial pueda reconocer la especie de copépodo, estos filtros trataron principalmente limpiar la imagen, y hacer más visible el copépodo y restando importancia al fondo de la imagen, de esta manera se logró alcanzar el objetivo: *“Obtener parámetros de entrada para el entrenamiento de la red neuronal aplicando filtros y estandarizando el tamaño de las imágenes”*.

En el capítulo 4 Marco Aplicativo en el desarrollo del prototipo, se construyo paso a paso el prototipo, es decir se aplico la teoría del modelamiento de redes neuronales artificiales propuestas por Eliasmith C., Anderson C. y también se aplicó el método ágil Iconix, con estas bases se realizó el objetivo *“Construir el modelo de red neuronal artificial para el reconocimiento de copépodos”*.

A partir del modelo planteado en el capítulo 4 Marco Aplicativo, se desarrollo el prototipo llamado SINERCO, que cumple con los requerimientos establecidos, así se logró el objetivo *“Construir el prototipo en base al modelo de procesos evolutivo incremental”*.

En el capítulo 5 Métricas de Calidad y Pruebas, se muestra como se evaluó y probó el prototipo, esta evaluación lanzó un resultado no satisfactorio ya que no se alcanzo el objetivo principal, el de reconocer las especies de copépodos con una capacidad del 90%, por otro lado el sistema es fácil de usar, según los resultados obtenidos por las métricas de calidad. Estas pruebas responden al objetivo *“Evaluar el prototipo mediante métricas de calidad”*.

6.2. ESTADO DE LA HIPÓTESIS

La hipótesis planteada para la siguiente investigación fue: *“Es posible identificar las especies de copépodos existentes en el lago Titicaca y Poopó mediante el reconocimiento de imágenes fotográficas tomadas del microscopio electrónico y procesar las mismas a través de una red neuronal artificial con una capacidad de reconocimiento superior al 90 %”* como respuesta a este planteamiento en el capítulo 5, Pruebas y Métricas de Calidad, se tiene que el prototipo no alcanzó el 90% de reconocimientos acertados, el prototipo solo tiene el 62% de credibilidad en el reconocimiento de las especies de copépodos.

6.3. CONCLUSIONES

Con la presente investigación se demostró que las redes neuronales artificiales pueden ser útiles en el área de biología, específicamente en el reconocimiento de especies de copépodos, además debido a su facilidad de uso se puede seguir entrenando a la red con nuevas especies.

Con más imágenes fotográficas para cada especie se pueden obtener mejores resultados y también se puede ampliar el reconocimiento de clases de copépodos de otros lagos.

6.4. RECOMENDACIONES

1. Para obtener un mejor reconocimiento separar las características únicas de los copépodos en imágenes, como el tercer exopodito que esta presente solo en el sexo masculino.
2. Para visualizar con mejor precisión la fotografia de los copépodos implementar una barra de herramientas para trabajar con imágenes.
3. Para los investigadores que tomen las imágenes fotográficas mediante el microscopio es recomendable centrar el copépodo para que se tenga mejor visibilidad del mismo y así más posibilidad de reconocimiento.

6.6 TRABAJOS FUTUROS

1. Para futuras investigaciones se puede usar este trabajo como base para ampliar el reconocimiento en el Plancton en general es decir tanto para zooplancton como para fitoplancton, en las superficies acuáticas de Bolivia.
2. Desarrollar un modelo predictivo para analizar la cadena trófica de los lagos Titicaca y Poopó.



7. BIBLIOGRAFÍA

Copépodos

ASTURNATURA (2007). *Los Copépodos*. Disponible en: <http://www.asturnatura.com/articulos/artropodos/copepod.php>

Armengol J. (1980) *Colonización de los embalses españoles por crustáceos planctónicos y evolución de la estructura de sus comunidades*. Universidad de Barcelona, Departamento de ecología, Facultad de Biología. Barcelona, España.

Del Castillo, M., (1992) *Introducción al estudio taxonómico del zooplancton*. Universidad Mayor de San Simón, Facultad de Ciencias y Tecnología, Departamento de Biología. Cochabamba, Bolivia.

Gilson H. (1964) *Lake Titicaca*. Ambeside, England.

Pinto, J., (1991) *El Lago Titicaca Sintesis del conocimiento limnológico actual*. CapítuloVI: Distribución del zooplancton en la parte boliviana del lago. Edición ORSTROM.

Ramos, C. & Dávila, Y. & Pinto, J. (2006) *Reporte preliminar de boeckella meteoris (crustácea, copépoda) en el lago Poopó*. Universidad Mayor de San Andrés, Unidad de limnología, Instituto de Ecología. La Paz, Bolivia.

Rocha, O. (2002) *Diagnóstico de los recurso naturales y culturales de los lagos Poopó y Uru Uru, Oruro Bolivia*. Convención RAMSAR, WCS/Bolivia. La Paz, Bolivia.

Redes neuronales artificiales

Choque, G. & Loza, R. & Méndez, R. (2006) *Redes Neuronales Artificiales Aplicaciones En Matlab*. Asociación de Investigación en Software Inteligente. La Paz, Bolivia.

Eliasmith C., Anderson C. (2003) *Neural Engineering: Computation, Representation and Dynamics in Neurobiological Systems*. Bradford Book, The MIT Press. Cambridge, Massachusetts, London, England.

Freeman J., Skapura D. (1993) *Redes Neuronales: Algoritmos, aplicaciones y técnicas de programación*. Publicaciones Addison Wesley Iberoamericana. Wilmington Delaware.

Hilera J. & Martínez V. (1995). *Redes neuronales artificiales: Fundamentos modelos y aplicaciones*. Addison-Wesley Iberoamericana, Buenos Aires Argentina.

Kasabov N. (1998) *Foundations of Neural Networks, Fuzzy Systems, and Knowledge Engineering*. The MIT Press Cambridge Massachusetts. London, England.

Russell S. & Norvig P. (1996). *Inteligencia artificial un enfoque moderno*. Prentice Hall Hispanoamericana, 1ra edición.

Metodología

Bunge M. (1979). *La investigación Científica*. Editorial Ariel: Barcelona, España.

Del Castillo, M., (1992) *Introducción al estudio taxonómico del zooplancton*. Universidad Mayor de San Simón, Facultad de Ciencias y Tecnología, Departamento de Biología. Cochabamba, Bolivia.

Pressman R. (2002). *Ingeniería del software: un enfoque práctico*. 5ta edición, Mc Graw Hill, España.

Schmuller J. (2003). *Aprendiendo UML en 24 horas*. Prentice Hall. EEUU.

Rosenberg D. & Stephens M. & Collins-Cope M. (2005). *Agile Development with ICONIX Process—People, Process, and Pragmatism*. Springer-Verlag New York,



ANEXO A: Glosario

Antenula:	Una antena pequeña, especialmente cualquiera del primer par de antenas en un crustáceo.
Autotrófico:	Él mismo produce sus alimentos para su existencia.
Bentónico:	Que forma parte del bentos: cuando las algas se encuentran flotando en el agua son planctónicas, si se hallan fijas al fondo marino, son bentónicas.
Bífido:	Que tiene un extremo dividido en dos partes, puntas o ramas.
Briófita:	<p>Cualquiera de las plantas terrestres sin semillas, que conforman la división Briofita.</p> <p>Existen por lo menos 18.000 especies divididas en tres clases: musgos, hepáticas y antocerotes. Las briófitas son extremadamente tolerantes a condiciones de sequía y congelamiento. Algunas briófitas son de uso ornamental, en los jardines de musgo. En la naturaleza, las briófitas inician la formación del suelo en terrenos estériles y mantienen su humedad, y reciclan los nutrientes en los ecosistemas forestales. Se encuentran en rocas, leños y en el humus de los bosques.</p>
Bromeliáceas:	Única familia de angiospermas del orden Bromeliales, con casi 2.600 especies. Todas las especies, salvo una, son nativas de América tropical y de las Indias Occidentales. Las flores de las Bromeliáceas son trímeras, como los lirios, pero con sépalos y pétalos contrastantes. Muchas Bromeliáceas son epífitas de tallos cortos. Muchas especies dan flores en una espiga larga, con brácteas coloridas debajo o a lo largo de la espiga. La mayoría tienen frutos carnosos, aunque algunas producen vainas secas. La barba del español y el fruto comestible de las ananás son los productos comerciales principales de la familia. Las hojas de ciertas especies contienen fibras con las cuales se fabrican cuerdas, telas y mallas. La bromeliácea más grande conocida es la gigantesca Puya raimondii de Perú y Bolivia, que puede alcanzar más de 9 m (30 pies) de alto. Ciertas especies se cultivan como plantas de interior ornamentales por sus flores y follaje coloridos.
Cadena Trófica:	<p>Sucesión de organismos vivos que se nutren unos de otros según un orden determinado:</p> <p>muchos peces comen productos contaminados, como plásticos o restos de metales, que pueden seguir la cadena alimentaria hasta llegar al ser humano.</p> <p>el fitoplancton es el primer eslabón de las cadenas tróficas marinas, seguido por el zooplancton.</p>
Chlorella:	<p>Cualquiera de las algas verdes del género Chlorella, que viven en aguas dulces o saladas y en el suelo.</p> <p>Tienen un cloroplasto caliciforme. Las chlorellas se emplean a menudo para estudiar la fotosíntesis, en experimentos con cultivos masivos, y para purificar aguas servidas. Como se multiplican rápidamente, y son ricas en proteínas y vitaminas del complejo B, han sido estudiadas como fuentes potenciales de productos alimentarios para el ser humano, tanto en la Tierra como en el espacio exterior. En EE.UU., Japón, Países Bajos, Alemania e Israel se han establecido granjas de chlorella, sistemas cerrados para proporcionar al hombre alimentos, agua y oxígeno.</p>
Cladóceros:	Crustáceo entomostráceo de pequeño tamaño, de caparazón bivalvo que deja libre la cabeza, provistos de antenas ramosas natatorias y de cuatro a seis pares de patas. Viven en bandadas en las aguas dulces y estancadas y en el mar.

Detritívoro:	Animal que se alimenta de organismos muertos.
Endopodito:	Pieza interior de cada uno de los apéndices bífidos de los crustáceos.
Epífita:	Que vive sobre otro, aunque sin ser parásito de él.
Esternito:	Parte del frontal del tórax.
Eutrofización:	Aumento gradual de la concentración de fósforo, nitrógeno y otros nutrientes vegetales en un ecosistema acuático que envejece, como un lago.

La productividad o fertilidad de un ecosistema de ese tipo aumenta a medida que incrementa la cantidad de material orgánico que se pueda descomponer en nutrientes. Este material ingresa al ecosistema principalmente por escurrimientos que llevan detritos. En la superficie se desarrollan a menudo floraciones algales, que impiden la penetración de la luz y la absorción del oxígeno necesarios para la vida subacuática.

Exopodito:	Pieza exterior de cada uno de los apéndices bífidos de los crustáceos.
Fitoplancton:	Flora de organismos, a menudo diminutos, que flotan libremente y derivan con las corrientes de agua.

Tal como la vegetación terrestre, el fitoplancton usa el dióxido de carbono, libera oxígeno y convierte los minerales en formas que pueden utilizar los animales. En aguas dulces, las miríadas de algas verdes a menudo colorean lagos y lagunas, y las cianobacterias pueden alterar el sabor del agua potable. Directa o indirectamente, el fitoplancton oceánico es la principal fuente de alimentos de todos los organismos marinos. Compuesto por grupos dotados de esqueletos silíceos, como las diatomeas y los dinoflagelados, la cantidad de fitoplancton varía estacionalmente, aumentando en primavera y otoño, en condiciones favorables de luz, temperatura y minerales.

Geniculado:	Parecido a la rodilla.
Humus:	Materia orgánica coloidal e inerte del suelo, derivada de la descomposición microbiana de sustancias vegetales y animales.

Su color varía entre marrón y negro, y consiste principalmente de carbono, pero también contiene nitrógeno y cantidades pequeñas de fósforo y azufre. Al descomponerse, sus elementos se convierten en formas utilizables por las plantas. El humus se clasifica de acuerdo a qué tan bien se incorpora al suelo mineral, los tipos de organismos implicados en su descomposición, y la vegetación de la cual deriva. Es apreciado por agricultores y jardineros porque proporciona nutrientes esenciales para el crecimiento de las plantas, incrementa la absorción de agua del suelo y mejora su explotabilidad.

Inocular:	Introducir en el organismo por medios artificiales el virus o la bacteria de una enfermedad contagiosa.
Limnología:	Subdisciplina de la hidrología encargada del estudio de las aguas dulces, específicamente lagos y estanques (tanto naturales como artificiales), incluyendo sus aspectos biológicos, físicos y químicos.

La especialidad fue establecida por François-Alphonse Forel (n. 1841–m. 1912) con sus estudios del lago Ginebra. Tradicionalmente, la limnología está muy relacionada con la hidrobiología, la cual se preocupa de la aplicación de principios y métodos de física, química, geología y geografía a problemas ecológicos.

Metamérico:	Segmento teórico del cuerpo de un invertebrado.
Micelio:	Masa de filamentos tubulares, ramificados (hifas), de los hongos que penetra el suelo, la madera y demás materia orgánica.
Musgo:	Especies de pequeñas plantas terrestres productoras de esporas, de la división briófitas, que se encuentran en todo el mundo, excepto en aguas saladas. Los musgos son plantas prehistóricas, simples, que han sobrevivido casi inalteradas desde el período pérmico (290–248 millones de años atrás). Los musgos que se hallan comúnmente en lugares húmedos y sombríos (p. ej., los suelos forestales) pueden tener un tamaño que oscila desde microscópico a más de 1 m (40 pulg.) de largo. Impiden la erosión y liberan nutrientes de los sustratos sobre los cuales crecen. Su ciclo vital muestra una clara alternancia de generaciones entre el gametofito sexual, con estructuras parecidas a tallos y hojas que producen huevos y esperma natatorio; y el esporofito, un pedúnculo erecto que termina en una cápsula de esporas (esporangio). Los musgos también se reproducen asexualmente por ramificación. El género <i>Sphagnum</i> , de importancia económica, forma la turba. Muchos de los llamados musgos no son briófitas, como el musgo irlandés (forma de alga roja); los líquenes musgo de barba, musgo de Islandia, musgo del roble y líquen de los renos; el musgo español (nombre utilizado para un líquen o planta aérea de las Bromeliáceas); y el musgo club (hierba siempre verde de la familia Lycopodiaceae).
Nauplios:	El primer nivel larval de los crustáceos que tienen un cuerpo desegmentado y un solo ojo.
Partenogénesis:	Tipo de reproducción sexual que consiste en el desarrollo de una célula reproductora hasta llegar a formarse un nuevo individuo, sin que se produzca fecundación; normalmente es el óvulo el que se desarrolla de este modo, como ocurre en ciertos crustáceos e insectos, pero a veces, en algunas plantas, como las algas, puede desarrollarse la célula reproductora masculina.
Plancton:	Organismos marinos y dulceacuícolas que, por su incapacidad de movilizarse o porque son demasiado pequeños o demasiado débiles para nadar contracorriente, existen en un estado de deriva, flotantes. El plancton es la base productiva de los ecosistemas marinos y dulceacuícolas, que provee alimento para los animales más grandes e indirectamente para los seres humanos, cuyas pesqueras dependen del plancton. Como recurso humano, el plancton recién ha comenzado a ser utilizado y desarrollado. La comunidad planctónica con afinidad vegetal se llama fitoplancton, y la comunidad planctónica con afinidad animal se llama zooplancton, pero muchos organismos planctónicos se describen mejor como protistas. La mayor parte del fitoplancton sirve de alimento para el zooplancton, pero parte de él es transportado debajo de la zona luminosa. El zooplancton se utiliza directamente como alimento de peces (como el arenque) o de mamíferos (como las ballenas), pero por lo general han pasado varios eslabones de la cadena alimentaria antes de que el plancton esté disponible para el consumo humano.
Rotífero:	Cualquiera de unas 2.000 especies de invertebrados microscópicos, pluricelulares y acuáticos, que constituyen la clase Rotífera o Rotaria. Las corrientes creadas por la corona del rotífero (cilios móviles dispuestos en un círculo en la cabeza) barren bacterias, protozoos y detrito hacia la boca. Los rotíferos comen también organismos más grandes (otros rotíferos, crustáceos,

algas). La faringe muscular contiene mandíbulas duras. La forma del cuerpo varía mucho entre las especies. Los rotíferos son comunes en el agua dulce de todos los continentes, aunque algunos viven en agua salada. Las especies varían bastante en su modo de vida: pueden ser de vida libre o parásitos, solitarios o de colonias, y de nado libre, reptantes o sedentarios.

Salobre: Que contiene mucha sal o tiene sabor de sal

Seta: Estructura carnosa esporífera de ciertos hongos, característica de la clase Basidiomycetes.

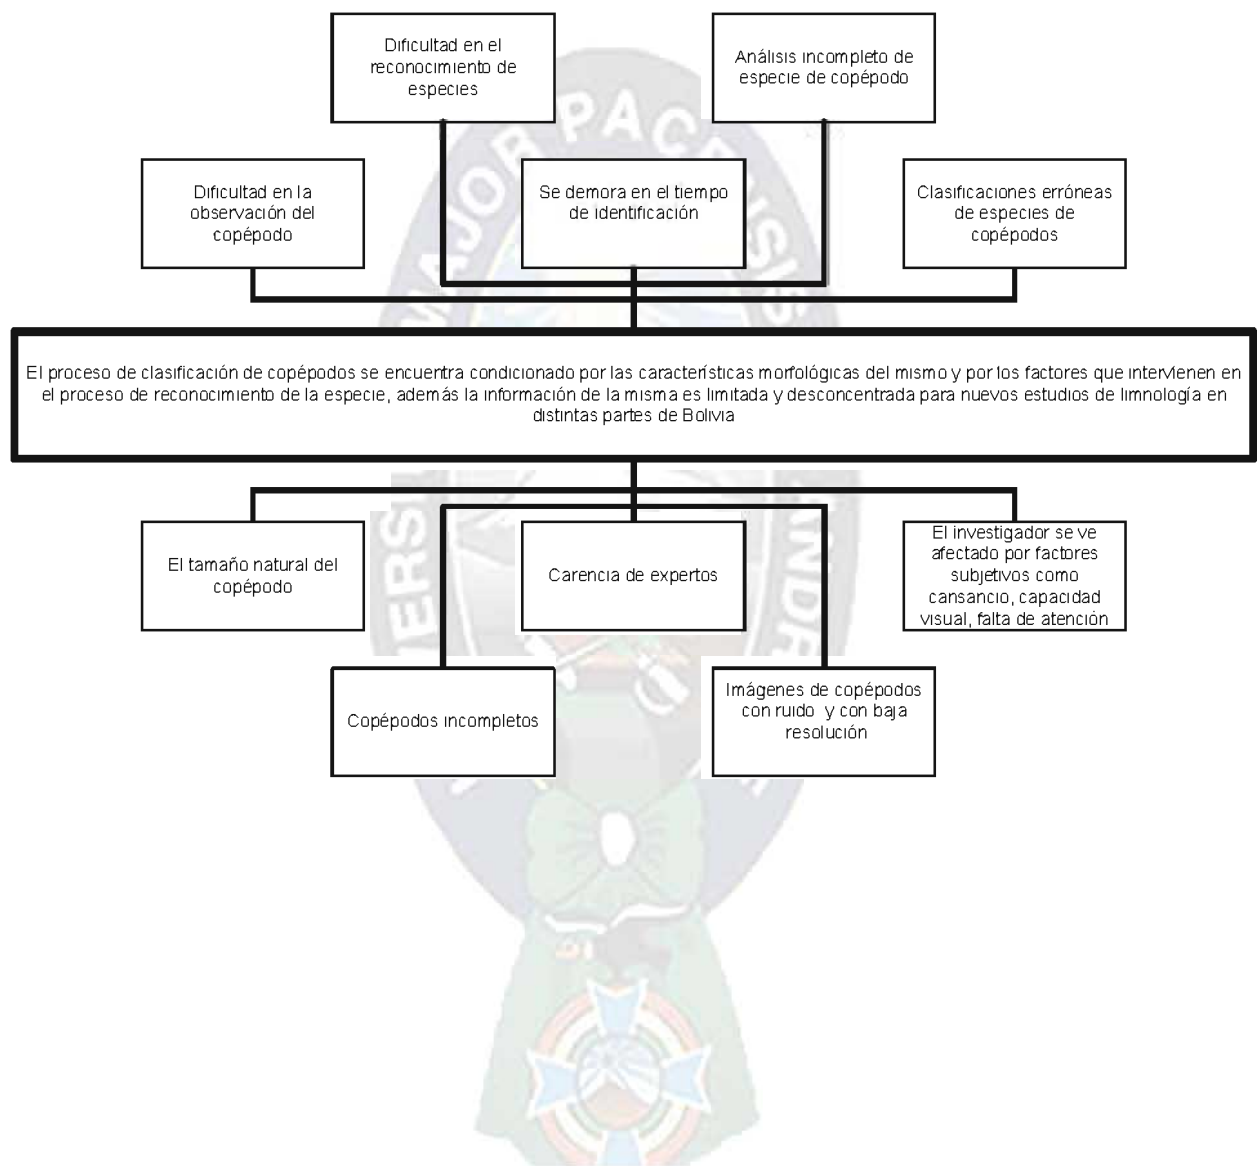
Surge del micelio que puede vivir centenares de años o unos pocos meses, según su provisión de alimento. Algunas especies dan filamentos celulares (hifas) que crecen en todas direcciones y forman una estera circular con un "anillo circundante de cuerpos fructíferos. Popularmente, el término "seta se refiere tanto a los esporíferos comestibles, como a los no comestibles o venenosos.

Tergito: El plato dorsal o porción dorsal de la cobertura de un segmento metamérico de un artrópodo especialmente: sobre el abdomen.

Zooplankton: Pequeños animales que flotan o nadan débilmente y van a la deriva con las corrientes de agua, y que sumados al fitoplancton constituyen el suministro de alimento planctónico del que dependen en última instancia casi todos los organismos oceánicos.

Comprende a muchos animales, desde los radiolarios unicelulares hasta los huevos o larvas de arenques, cangrejos y langostas. El plancton permanente (holoplancton), como los protozoos y copépodos, pasan su vida como plancton. El plancton temporal (meroplancton), como son las estrellas de mar, almejas, gusanos y otros animales jóvenes bentónicos, viven y se alimentan como plancton hasta que se hacen adultos.

ANEXOS B: Árbol de Problemas



ANEXO C: Árbol de Objetivos

